

六模型 QKV 投影需求

一个 token、静态权重与原生语义矩阵

2026 年 9 月 25 日

研究结论。六个选定层的窗口内权重写入均为零，双边界 $RI = \infty$ ；但 ports 输入从 80 KiB 增至 1272 KiB，预驻留容量从 10 MiB 增至 159 MiB。相同静态端点并不表示相同投影规模。本文保留 Qwen 原生输出门控、Hy3 的实际 Q 宽度和融合 QKV 的语义切分。

1 对象、来源与真实矩形

本稿延续已通过的 Step 1/2/3，以 Step 3 提交 e472a0d 为起点。每个模型只分析已选完整/全局 GQA 子层的一次 token 投影；层号从 0 起，不乘主干层数。共有 6 个工况、20 个语义矩阵。隐藏向量 $x \in \mathbb{Z}^D$ 相同地输入各投影。矩阵按 $W \in \mathbb{Z}^{N \times D}$ 排列， N 为输出行， D 为输入列。

模型 / 层	D	H_q/H_{kv}	d_{QK}/d_V	G 宽	N_Q, N_G, N_K, N_V
Qwen3.5-2B / 3	2048	8/2	256/256	2048	2048, 2048, 512, 512
Ministral 3 8B / 0	4096	32/8	128/128	-	4096, -, 1024, 1024
Qwen3.6-35B-A3B / 3	2048	16/2	256/256	4096	4096, 4096, 512, 512
Hy3 (295B) / 1	4096	64/8	128/128	-	8192, -, 1024, 1024
Ling-1T / 4	8192	64/8	128/128	-	8192, -, 1024, 1024
MiMo-V2.5-Pro / 7	6144	128/8	192/128	-	24576, -, 1536, 1024

表中每一输出宽度 N_j 对应完整矩形 $W_j = N_j \times D$ ；无 G 时省略该矩阵。Ministral 固定为官方 Base 2512；Qwen3.6 使用其确切 checkpoint，官方复用的 qwen3_5_moe 实现名不改变模型身份。

门控与维度 两款 Qwen 的原生 q_proj 按 head 交错输出 Q 和等宽 Attention output gate G 。Qwen3.5 为 4096×2048 ，Qwen3.6 为 8192×2048 ，分别拆成 Q/G 两个语义 bank。 G 经 sigmoid 后门控 Attention 输出，不是额外 query head、KV 状态或 MoE router。Hy3 显式 $d_{QK} = 128$ ，故 Q 为 $64 \times 128 = 8192$ ，不能由 $D/H_q = 64$ 代替头维。

融合与原生精度 Ling 的融合矩阵为 10240×8192 ，MiMo 为 27136×6144 。固定源码的切分分别给出 Q/K/V 宽度 (8192, 1024, 1024) 与 (24576, 1536, 1024)。前五款保存的原生浮点配置为 BF16；MiMo 为 FP8 E4M3 混合产物。本文使用各数值角色每元素 1 Byte 的 INT8 逻辑参考，不声称已验证六模型 INT8 精度。

范围 不计 Attention 输出投影 W_O ，不把后续 KV 建立/追加加入静态权重 Q_R 。数字部分和、norm、RoPE、sigmoid、逐元素门控和 Value 缩放属于算子交接，不重复作为本次投影输入。

2 同一个 token 的两种边界

固定共享版本为 `WS128-INT8-semantic-banks-v1`。Q、可选 G、K、V 各有独立的 128×128 tile 网格，不跨语义矩阵合并尾块。融合权重可无复制地切片或重排；源码的融合不合并 CIM 接收端。权重在窗口前预驻留，每个 tile 求值一次；假设驻留空间足够，不引入容量不足重载。

分项 记 $c(n) = \lceil n/128 \rceil$ ，输入、权重宽度分别为 b_x, b_W 。对任一实际矩阵 j ，有

$$Q_{S,j}^{\text{op}} = Db_x, \quad Q_{S,j}^{\text{ports}} = c(N_j)Db_x, \quad (1)$$

$$Q_{R,j}^{\text{op}} = Q_{R,j}^{\text{ports}} = 0, \quad C_j = c(N_j)c(D), \quad (2)$$

$$C_{R,j} = N_j Db_W, \quad C_{R,j}^{\text{alloc}} = 128^2 b_W c(N_j)c(D). \quad (3)$$

本稿 $b_x = b_W = 1$ 。 $C_{R,j}$ 是有效驻留容量， $C_{R,j}^{\text{alloc}}$ 是完整逻辑 tile 槽位容量，均区别于累计写入。每个 tile 接收其输入方向的有效列片，输出方向不同的 tile 分别计费。

汇总与输入身份 若实际矩阵数为 m ，operator 分项都引用同一个 x ，所以

$$Q_S^{\text{op}} = \sum_j Q_{S,j}^{\text{op}} - (m-1)Db_x = Db_x, \quad (4)$$

$$Q_S^{\text{ports}} = Db_x \sum_j c(N_j), \quad C = c(D) \sum_j c(N_j), \quad (5)$$

$$Q_R = 0, \quad \text{RI}^{\text{op}} = \text{RI}^{\text{ports}} = \infty. \quad (6)$$

ports 接收直接相加；operator 按同源身份去重，扣除量在机器数据中单列。调用数由 ports 记录。

完整代入：Qwen3.6 的一个 token $D = 2048$ ，Q/G/K/V 输出为 (4096, 4096, 512, 512)，输出块数为 (32, 32, 4, 4)，输入块数为 $2048/128 = 16$ ，因此

$$Q_S^{\text{ports}} = 2048(32 + 32 + 4 + 4) = 147456 \text{ Byte},$$

$$Q_S^{\text{op}} = 4 \times 2048 - 6144 = 2048 \text{ Byte}, \quad Q_R = 0, \quad \text{RI} = \infty,$$

$$C = 16(32 + 32 + 4 + 4) = 1152,$$

$$C_R = C_R^{\text{alloc}} = 2048(4096 + 4096 + 512 + 512) = 18874368 \text{ Byte} = 18 \text{ MiB}.$$

同一个 x 的四个独立入口扣除三份重叠共 6144 Byte； $Q_R = 0$ 来自权重预驻留。

模型	Q_S^{ports} (Byte)	Q_S^{op} (Byte)	调用 / tile	容量 (MiB)
Qwen3.5-2B	81,920	2,048	640	10
Minstral 3 8B	196,608	4,096	1,536	24
Qwen3.6-35B-A3B	147,456	2,048	1,152	18
Hy3 (295B)	327,680	4,096	2,560	40
Ling-1T	655,360	8,192	5,120	80
MiMo-V2.5-Pro	1,302,528	6,144	10,176	159

本表所有 $Q_R = 0$ 、 $\text{RI} = \infty$ ；调用数等于 resident tile 数。所有语义矩形两轴均整除 128，有效容量等于分配容量；MiB 为 2^{20} Byte。

比例不能替代规模 MiMo 相对 Qwen3.5 的 ports 输入、tile 数和容量均为 159/10 倍，但静态 RI 相同。Ling 与 Hy3 的输出宽度一致，Ling 输入 D 加倍，因此其局部输入、调用和容量均加倍。这些是需求差异，不是并行时间、token/s 或硬件适合度预测。

3 20 个语义矩阵与易错边界

模型	分项	Q_S^{ports} (Byte)	调用 / tile	容量 (MiB)
Qwen3.5-2B	Q	32,768	256	4
	G	32,768	256	4
	K	8,192	64	1
	V	8,192	64	1
Ministral 3 8B	Q	131,072	1,024	16
	K	32,768	256	4
	V	32,768	256	4
Qwen3.6-35B-A3B	Q	65,536	512	8
	G	65,536	512	8
	K	8,192	64	1
	V	8,192	64	1
Hy3 (295B)	Q	262,144	2,048	32
	K	32,768	256	4
	V	32,768	256	4
Ling-1T	Q	524,288	4,096	64
	K	65,536	512	8
	V	65,536	512	8
MiMo-V2.5-Pro	Q	1,179,648	9,216	144
	K	73,728	576	9
	V	49,152	384	6

每个分项均有 $Q_R = 0$ 、 $RI = \infty$ ，operator 单独入口为本模型的 D Byte。本表省去这三列的重复值；完整双边界分项、布局和窗口仍逐项保存在 JSON/CSV。

Qwen output gate 的实际增量 Qwen3.5 的 G 增加 32768 Byte 接收、256 次调用和 4 MiB 权重；Qwen3.6 的 G 增加 65536 Byte、512 次和 8 MiB。漏掉 G 后静态 RI 仍为 ∞ ，所以只检查 RI 无法发现此错误。Qwen 原生行号为 Q: $2hd + j$ ，G: $2hd + d + j$ ， $0 \leq j < d$ ；独立检查证明两集合互斥并完整覆盖原生投影。

MiMo 的 192 不意味着本行存在半宽尾块 QKV 的输入轴是 $D = 6144$ ，Q/K 输出轴分别为 $128 \times 192 = 24576$ 和 $8 \times 192 = 1536$ ，V 输出为 1024。这四个长度均为 128 的倍数。Q/K bank 在同一语义矩阵内允许跨 head 分块，不另加每头对齐约束。后续 Attention 的 $d_{QK} = 192$ 输入尾片属于另一矩阵形状，不能搬到此行重复填充。

融合语义分块 Ling 的 Q/K/V 行区间依次为 $[0, 8192)$ 、 $[8192, 9216)$ 、 $[9216, 10240)$ ；MiMo 为 $[0, 24576)$ 、 $[24576, 26112)$ 、 $[26112, 27136)$ 。独立检查确认每组切片无重叠且恰好覆盖原生融合矩阵；没有复制驻留权重。

4 固定证据、独立复核与复现

所有原始路径相对 `tasks/task2_table_II_workloads/`。六模型原始 `config` 位于各自 `literature/01_.../raw/` 至 `literature/06_.../raw/`，结构卡、原件 SHA-256、固定 URL 与完整 revision 收录于 `data/config.json`（本计算目录），配置字段与实现原文锚点逐条见 `data/checks.json`。

模型	固定 checkpoint revision 与 QKV 实现定位
Qwen3.5-2B	15852e8c16360a2fea060d615a32b45270f8a8fc 共享 <code>modeling_qwen3_5.py</code> :749–821; <code>text_config</code> 层型、头数与 <code>head_dim</code> 。
Ministral 3 8B	d4883f9b36aa2e5d775730d3fdbba3d30de51a8ef 共享 <code>modeling_ministral3.py</code> :111–172; HF <code>text_config</code> 与原生 <code>params.json</code> 互证。
Qwen3.6-35B-A3B	995ad96eacd98c81ed38be0c5b274b04031597b0 共享 <code>modeling_qwen3_5_moe.py</code> :751–825; Q/G 按头切分和 sigmoid 使用。
Tencent Hy3	a960ebc3da325ba167f069f76c41eb62c9280d22 共享 <code>modeling_hy_v3.py</code> :210–281; 显式 <code>head_dim</code> 覆盖 D/H_q 回退。
Ling-1T	268f2aa76aa8cf5b36ca33805481cea91133327e 模型原件 <code>modeling_bailing_moe_v2.py</code> :441–502; 融合线性层和按 <code>head</code> 数切分。
MiMo-V2.5-Pro	21d1ecfec7bd70f31be25ca49d7edd21f003659 模型原件 <code>modeling_mimo_v2.py</code> :215–286,352–405; 全局层、独立 V 维和融合切片。

共享 Transformers 快照来源为固定 commit 2c4914f；完整版本与源文件 hash 由原始来源清单保留。Ministral 的原生 `v_head_dim=null` 未启用特殊 V 维，固定实现明确 V 使用 `head_dim=128`。

真正独立的预期值 主流程使用共享 `counting.py`；`scripts/check.py` 不导入生产计数函数。它从原始 `config` 重提维度，并检查固定实现锚点，逐个真实 tile 枚举输入列区间及有效矩形面积。operator 使用 (token identity, element index) 集合求并集；容量来自 tile 面积累计。六工况的所有结果叶字段、20 个语义矩阵的双边界、布局、窗口与调用完全一致。Ministral 与 Qwen3.6 两个重叠工况重新生成后，与 pilot 完整 case 逐字段回归通过，未复制结果。

复现与交付 本目录 `scripts/generate.py` 默认只检查生成物，`scripts/check.py` 默认只复核；显式 `--emit` 才刷新数据。`scripts/build.sh` 先运行两者再用 XeLaTeX 编译；`scripts/render.py` 渲染每页供目视检查。最终 PDF 的逐页 QA 记录位于 `data/pdf_qa.json`；`DELIVERY.json` 记录可审阅版本和 SHA-256。本稿不修改共享计量、原始证据或 pilot，不启动 Step 5，也不从总 RI 推断器件排名或完成时间。