

2D NOR Flash

二进制局部数字求值与完整页/扇区更新

固定 128×128 INT8 矩阵与 INT8 输入，采用二进制 NOR 状态和局部精确数字归约。参考点输入吞吐约 4.00 MB/s、完整更新吞吐约 79.7 kB/s，ridge 约 50.2。这是明确资源和更新粒度下的条件性设计估算。

1 状态模式与证据的分工

NOR 的非易失状态可以表示二进制位，也可经精调表示连续模拟权重；两者有不同的成功终点。本章选择**二进制存储加局部数字计算**：读出各 bit 的 0/1 判决，数字逻辑完成乘法、符号处理和累加。一个 INT8 权重由八个逻辑存储 bit 表示，不要求某个 cell 提供 256 个稳定电流值。矩阵共 131072 个逻辑存储 bit；一次输入 $B_S = 128$ Byte，完整矩阵更新 $B_R = 16384$ Byte，结果为 128 个 24-bit 有符号容器。

NOR-04 则是经过阵列改造的 180 nm ESF1 模拟分类器。浮栅电荷改变晶体管阈值和导通电流，输入激励与已调好的权重产生电流贡献，列上求和，差分连接表示正负权重。其第一层采用二电平输入，并不意味着其权重是普通二进制 Flash。该原型有 101780 个浮栅 cell、784-64-10 网络，输入先串行装入 785-bit 寄存器。论文的亚微秒量级描述网络传播，不是本章 INT8 完整服务间隔；Fig. 14 的振荡与输入电路限制也不能略去。

NOR-05 给出 100-cell 调谐实验：平均约 10 次脉冲达到 3% 调谐误差，35 次达到约 0.3%。其 Fig. 2 包含全擦初始化、读状态、模型更新和交替擦写；Fig. 3 的 $100 \mu\text{s}$ 编程脉冲与 2.5 ms 擦除脉冲是动力学表征条件，不是完整权重调谐时延。NOR-04 原型实际采用约 5% 单 cell 导入目标，后续半选扰动也有影响。两篇同技术线分别支持模拟机制和调谐方法，不能当作独立的二进制写入验证。

本章没有把模拟调谐的 10/35 次脉冲加在厂商页编程时间之后，也没有把普通 binary 页编程终点解释为模拟电流精度。所选数字路径与 binary 更新相容：判决只需满足数字读窗，权重位权和输入补码符号在数字域处理，输入符号位取 -2^7 。它是一种包含本地 NOR 感测和归约资源的参考宏；库内尚无对应该映射的已制造 NOR DCIM 宏，因此不将本估算标成原型实测。

证据层次	本章采用方式
NOR-01	完整随机二进制读周期的 100/120/130 ns 量级锚点；保留原电压、容量和速度选项。
NOR-02	256 Byte 页、4 KiB sector、内部自定时 program/erase 与 BUSY 完成终点。
NOR-04/05	说明电流域 VMM、精调与普通 binary 状态的区别，不直接提供本设计的读写时间。
共享基线	导入 R0 的本地计算资源、操作计数、28 nm 数字节拍、写端口和统一吞吐 API。

表 1: 原始证据、参考结构和推导分开。不同来源只在明确的二进制模式下互补。

2 本地读分片与原生更新域的映射

主布局保持共享 R0：每轮处理 32 个输入项、16 个输出，八位权重并行、输入逐 bit 展开。实现这一轮需要 **32 个独立读分片**，每片 **128 个二进制 sense amplifier (SA)**，共 **4096 SA**，以及 16 条 32 项数字归约/累加通道、128 个 24-bit 输出累加寄存器。一个读分片在一轮只选择自己的一个局部字线，不要求普通 NOR 在同一位线上同时辨认 32 个 cell。

按输入索引 $i = 0, \dots, 127$ 和输出 $o = 0, \dots, 127$ 映射，分片 $s = i \bmod 32$ 保存 $i = s, s+32, s+64, s+96$ 四行，每行 128 Byte，因此每片有效容量 512 Byte。读轮的组号 $g = 0, \dots, 3$ 使各片选取输入行 $i = s + 32g$ ；输出组 $h = 0, \dots, 7$ 选择其中连续 16 个权重，共 128 bit。每个输入 bit 重读这些状态，沿用 R0 的无跨输入位复用、无跨向量流水条件。

独立读分片不等于独立擦除域。主布局将相邻八片的 $8 \times 512 = 4096$ Byte 放在一个 4 KiB sector，四个 sector 恰好覆盖整矩阵。每片的两张 256 Byte 页，各保存两个完整逻辑输入行；一个 sector 共 16 页，整矩阵共 64 页。该组织需局部字线/位线选择、读偏置缓冲和感测隔离，并让同一 sector 的八片在擦除时共享高压选择及擦除控制。编程时只选一页，其他页受抑制；全宏只有一个 program/erase 控制域和一套活动页缓冲。

NOR-02 规定页与 sector 的外显更新粒度，没有规定一个 sector 只能有一个本地读通道。本章把读分段与高压更新域分别设计，不是声称 *W25Q128JV* 内部已有这 32 个并行端口。128-bit 本地数据接口、128-SA 读宽和 256-Byte 内部页算法是三个不同资源；接口宽度不能推导 128 个 cell 同时编程，更不能推出 32 页并行写。

项目	主布局的资源或计数
逻辑/物理有效数据	16 KiB 权重，八个 binary bit/INT8；无额外模拟差分编码
读分片	32 片，每片 512 Byte、128 SA；每轮读 4096 bit
更新层次	8 读片/sector，4 sector，16 页/sector，64 页/矩阵
写资源	一个 256-Byte 页缓冲，一个更新控制域；本地装入接口 128 bit
数字计算	每轮 32 项 $\times$ 16 输出；输入八轮位展开；两拍边界控制
物理容量	4×4 KiB=16 KiB；sector 不与无关状态共享，无需保存其他 payload

表 2: 这是为一份矩阵配置的内部并行分片，不是复制 32 份独立服务单元。没有等面积约束。

原生更新可以合法聚合成整矩阵：页地址对齐且不跨界，64 次完成的页编程覆盖每个权重恰好一次；四个擦除操作覆盖它们的旧状态。所选事务是整矩阵任意重写，未使用预擦空白区、增量 append 或矩阵交换来隐藏擦除。稀疏更新及含无关有效数据的共享 sector 需要另算读改写，不能沿用本章 B_R 。

3 Streaming: 完整二进制读与数字归约

采用共享 API `dcim_service` 计算 R_0 , 操作次数为

$$N_D = N_{rd} = 8 \times 1 \times 4 \times 8 = 256, \quad \Delta_S = 256(t_{rd} + T_D) + 2T_D.$$

一轮二进制读提供 32×16 个 INT8 权重; 随后一拍完成相应输入 bit 的选择乘法、32 项归约、符号处理和 16 个输出的部分和更新。公共 $T_D = 2/5/10$ ns 分别取自共享 short/reference/long 情景; T_I 和 ADC 时隙不用于本数字路径。必要读偏置建立、选择和感测都放入完整 t_{rd} , 不再重复叠加一个“cell read”周期。

NOR-01 PDF p. 85 Table 57/58、p. 86 Table 59 的随机读周期分别为 100/120/130 ns。100 ns 档针对 512 Mb、 $V_{IO} = V_{CC} = 2.7\text{--}3.6$ V、 -55 至 105°C ; 120 ns 档覆盖更多容量与 125°C ; 130 ns 档包含低至 1.65 V 的 I/O 条件。原表分别给出最小允许读周期 t_{RC} 和最大地址到输出延时 t_{ACC} , 数值一致。这里用它们锚定三档完整本地二进制读预算, 不是将 t_{ACC}^{-1} 直接称作向量吞吐。

这一步有明确工程桥接: 商品的外部 16-bit 接口并不等于本地 bitline 感测宽度, 本设计另配置 128-SA 宽的局部感测和 32 组读偏置/选择电路; 假定其负载、输出隔离和数字读窗允许 100–130 ns 的完整周期。NOR-01 的原工艺为 65 nm、介质电压并非 0.9 V; 28 nm 只指共享数字外围参考。既不凭工艺缩小比例加速 NOR, 也不从 SPI 的 50/133 MHz 或连续数据速率推导介质读时间。移植后的宽度与读时间相容性仍是待电路验证的主要条件。

情景	t_{rd} (ns)	T_D (ns)	读占用 (μs)	数字/边界 (μs)	总计 (μs)
短	100	2	25.600	0.516	26.116
参考	120	5	30.720	1.290	32.010
长	130	10	33.280	2.580	35.860

表 3: 阶段按顺序执行。参考点二进制读占完整 streaming 周期的约 96.0%。

在参考点, $\rho = 128/(32.010 \mu\text{s}) \approx 4.00$ MB/s。虽然每轮物理读出 4096 bit, 整个向量又有 256 轮, 逻辑输入分子始终只有 128 Byte; 反复感测 resident 权重也不是新的 workload 更新。输出寄存就绪由末拍覆盖, 输出 Byte 不加入到 B_S 。

三档读周期来自不同商品条件, 用于构造参考预算而非同一芯片的实测统计角。固定参考数字节拍和写预算, 仅将本地读预算 120 ns 改为 96/144 ns, ρ 与 ridge 约变化 $+23.8\%/ -16.1\%$, τ 不变。这揭示读桥接的重要性; 不能把数字外围只占少量时间误解为整体估算不依赖本地感测设计。

4 Resident：页编程、sector 擦除和完成终点

NOR-02 PDF p. 37 规定 Page Program 向已擦为 FFh 的区域写入 1-256 Byte；命令与数据装入结束后，才启动内部自定时 t_{PP} 。PDF p. 39 规定 4 KiB Sector Erase 把整个 sector 置为 1；p. 14 定义 BUSY 在操作结束后归零。p. 66 的详细 AC 表给出 $t_{PP} = 0.4/3$ ms、 $t_{SE} = 45/400$ ms (typ/max)。这些是普通 binary 状态的完整内部操作，所需脉冲、内部校验和恢复已由控制器覆盖，不能再套一个未报告的重试倍数或模拟精调循环。

本章采用持续整矩阵任意重写，先逐 sector 完成擦除，再串行装入并提交有效页；四个 sector 的顺序可变，但不能并行借用 32 个更新引擎。每页在本地 128-bit 接口需 $256 \times 8/128 = 16$ 拍装入，加准备与完成各一拍，共 $18T_D$ ；每个擦除命令另计两拍本地控制。页缓存和完成信号处于宏内部，SPI 线缆命令传送在所选局部边界之外。专用高压建立不按低压 T_D 替换，而保留在毫秒量级完整内部块中。

主布局每次擦除支撑 $N_{p/e} = 16$ 个有效页。等效页服务与完整矩阵服务分别为

$$\begin{aligned}\Delta_{R,\text{page}} &= 18T_D + t_{PP} + \frac{t_{SE} + 2T_D}{16}, & B_{R,\text{page}} &= 256 \text{ Byte}, \\ \Delta_R &= 64(18T_D + t_{PP}) + 4(t_{SE} + 2T_D), & B_R &= 16384 \text{ Byte}.\end{aligned}$$

同一组字节和时间一起聚合，所以两种写法得到相同 τ 。参考点的 4 次 45 ms 擦除、64 次 0.4 ms 页编程及 $5.8 \mu\text{s}$ 装入/控制合计

$$\Delta_R = 180 \text{ ms} + 25.6 \text{ ms} + 0.0058 \text{ ms} = 205.6058 \text{ ms}.$$

内部擦除占约 87.55%，页编程占约 12.45%，低压装入与控制不到 0.003%。NOR-02 p. 38 也明确指出较高输入时钟下 Quad 输入的收益会被内部页编程时间淹没；缩短装入不能消除 t_{PP} 和 t_{SE} 。

互补核查不更换主预算。NOR-01 p. 45 Table 16 的 512 Byte buffer 编程为 $420/1050 \mu\text{s}$ ，128 KiB sector 擦除为 $410/1100$ ms；擦除已含把所有 word 预编为零。其 typ 条件是 25°C 、3.0 V、10000 次循环和随机数据，max 条件另见注 31。 $1.64 \mu\text{s}/\text{word}$ 是满 buffer 的摊销量，不能当作独立 word 完成延时；p. 2 摘要速率不能优先于这个详细条件表。本章没有把 NOR-01 的 128 KiB 擦除时间配到 NOR-02 的 4 KiB 粒度。

更新终点是页/sector 操作完成、状态可数字读取；初始上电、保护配置和异常操作恢复不属正常重复服务。NOR 的正常读不破坏状态，本时间窗口不增加 refresh 或 restore。有限 program/erase 耐久度单列为寿命约束，不并入瞬时 τ 。

5 成对结果、组织对照与适用范围

采用共享吞吐 API，统一计算

$$\rho = \frac{B_S}{\Delta_S}, \quad \tau = \frac{B_R}{\Delta_R}, \quad \text{RI}^* = \frac{B_S}{B_R} \frac{\Delta_R}{\Delta_S}.$$

短、参考情景均保留 NOR-02 的 typ program/erase；长情景采用其 max 列，分别配共享外围和上一节读预算。这是少量可解释的配对，不是已测联合 PVT 分布，也不是 NOR 材料边界。

情景	Δ_S (μs)	Δ_R (ms)	ρ (GB/s)	τ (GB/s)	RI^*
短	26.116	205.602320	0.004901	7.969e-05	61.51
参考	32.010	205.605800	0.003999	7.969e-05	50.18
长	35.860	1792.011600	0.003569	9.143e-06	390.4

表 4: 同一 binary 映射的三组完整服务。每行 $B_S = 128$ Byte、 $B_R = 16384$ Byte；显示位数仅供复算。

参考点手算为

$$\text{RI}^* = \frac{128}{16384} \frac{205605800}{32010} = 50.1810 \dots$$

若用等效页， $\Delta_{R,\text{page}} = 3212590.625$ ns，粒度因子变为 $128/256 = 1/2$ ，结果相同。不能把 $\Delta_R/\Delta_S \approx 6423.2$ 直接称作 ridge。主配对范围约为 $\rho = (3.57\text{--}4.90) \times 10^{-3}$ GB/s、 $\tau = (9.14 \times 10^{-6}\text{--}7.97 \times 10^{-5})$ GB/s、ridge 约 50.2–390.4；它不是相互独立端点相除的任意组合。

5.1 唯一组织对照：每个读分片独占一个 sector

若实现约束使每个 512-Byte 读分片必须独占一个 4 KiB sector，仍有 32 个读分片和 4096 SA，但分配容量增加为 128 KiB。有效页仍为 64 页，擦除数增为 32， $N_{p/e} = 2$ ，未用容量不能加入 B_R 。在同一参考时间下得到：

组织	分配容量	擦除数	Δ_R (ms)	τ (GB/s)	RI^*
主布局	16 KiB	4	205.605800	7.969e-05	50.18
独占 sector	128 KiB	32	1465.606080	1.118e-05	357.7

表 5: 保持 32 个读分片、4096 SA 和参考读时间，只改变读分片与擦除域的归属。两行 ρ 相同，物理容量不要求相等。

此对照 ρ 不变， τ 降至主布局的约 $1/7.13$ ，ridge 增至约 357.7。区别来自实际有效页/擦除域利用率，既不是接口传输速率，也不是 binary cell 编程速度变了。主布局的共用 sector 与对照的独占 sector 都需相应高压隔离设计；读端口数本身不决定擦除域数。若实物只能实现后者，应采用对照值，不应保留主布局的四次擦除预算。

5.2 边界、可复现性和后续使用

本章以同一份 binary 状态连接两路估算：读资源保持 R0，写资源始终单域。读写共享阵列与高压选择，估算中不重叠，因此 $P \leq \min(\rho, \tau \text{RI})$ 只是必要上界，不保证两路同时达到各自独立峰值。静态权重 $Q_R = 0$ 时进入 $\text{RI} = \infty$ 分支，只受 ρ 限制。

主要待验证条件是：128-SA 宽读分片的读窗/负载、32 片并行选择，sector 内八片共享擦除与页选择的隔离，以及在上述改造下仍保留所采用的完整 program/erase 时间。没有同芯片全链路实测，并不阻止本条件预算；也不能据此将结果推广为所有 NOR CIM、特别是连续模拟精调模式的性能。

6 证据入口与复现说明

本地 `data/inputs.json` 分开记录原值和结构选择；复算脚本直接导入共享 JSON 与 API，保存二者和源 PDF 哈希，校验位覆盖、页/sector 映射、阶段覆盖、单位、成对结果和聚合一致性。默认复算只读，`--emit` 显式刷新结果与表格。证据全文定位和桥接边界见 `notes/parameter_evidence.zh.md`。

6.1 原文定位与条件保留

以下页码均为本地 PDF 页序，从 1 开始。资料保存在 `literature/03_nor_2d/`，源标识及 SHA-256 与本地 `source_manifest.json` 一致。

1. NOR-01, Infineon, *128 Mb / 256 Mb / 512 Mb / 1 Gb GL-S MIRRORBIT Flash, Parallel, 3.0 V, Military*, 002-18741 Rev. *E, 2024-09-04. p. 22 给出内部算法及 1→0 编程/擦除恢复为 1 的语义；p. 45 Table 16 给出带条件的完整更新；pp. 85–87 给出随机与页读时序。65 nm MirrorBit 的物理单元组织并未用于本章一 bit 一数字判决的 cell 面积换算。
2. NOR-02, Winbond, *W25Q128JV: 3V 128M-BIT Serial Flash Memory with Dual/Quad SPI*, Revision G, 2019-04-08. p. 5 给出 256-Byte 页、16 页/4 KiB sector 和耐久/保持特性；p. 14 是 BUSY 定义；pp. 37–39 是 program/erase 起止；pp. 65–66 是接口与内部时序。p. 66 的注 5 仅为带该注号条目的表征说明，不自动扩展为所有 program/erase 数字的实测条件。
3. NOR-04, X. Guo 等, *Fast, Energy-Efficient, Robust, and Reproducible Mixed-Signal Neuromorphic Classifier Based on Embedded NOR Flash Memory Technology*, IEDM, 2017. pp. 1–2 的设计、导入精度和测试条件，p. 3 Figs. 1/2/6 的机制和结构，p. 4 Figs. 9/14 的导入统计与动态响应；55 nm 后续结果属于预测，未用作本章实测时间。
4. NOR-05, F. Merrih Bayat 等, *Model-Based High-Precision Tuning of NOR Flash Memory Cells for Analog Computing Applications*, DRC, 2016. p. 1 是算法和 100-cell 实验；p. 2 Fig. 2 为调谐流程、Fig. 3 为脉冲表征、Figs. 5/6 为精度与脉冲数。与 NOR-04 同团队/技术线。

6.2 阶段、寿命与复算检查

共享规则 R4 在此有两处作用：完整随机读预算替代其已含的选择/建立/感测；完整 BUSY program/erase 替代内部脉冲、verify 和恢复。公共数字归约、页数据装入和本地控制另算。未报告的高压切换或内部重试没有再人为加一个跨介质统一倍数。

NOR-02 p. 5 标称每 sector 至少 10^5 次 program/erase 及超过 20 年保持。持续任意整矩阵重写每次消耗每个活动 sector 一次擦除寿命；这些商品条件不是改造后宏的寿命保证，也不是可以无限持续以 τ 更新的承诺。主预算未用这些寿命数去折减瞬时吞吐。

从本案例目录执行 `python scripts/check_nor.py` 可只读核对结果；修改明确输入后执行同一脚本的 `--emit`，再执行 `sh scripts/build.sh`。构建采用 XeLaTeX/ctex/Fandol，渲染检查全部页面。共享参数变更会触发哈希/派生结果不一致，需复核后显式更新；不会静默沿用旧表。