

# 3D vertical AND FeFET

## 二状态局部 CIM 服务估算

### 1 主模式、服务边界与证据身份

本例归入 3D FeNOR / vertical FeFET 技术族，主实现明确采用 FENOR-02 的 **3D vertical AND FeFET** 二状态存储，配局部二进制感测和数字乘加。它与 2025 年 NOR-type FeFET 的拓扑、栅堆栈和偏置有区别。本文构造的是有条件的 28 nm CMOS 外围参考设计；器件脉冲、小阵列验证和仿真共同提供依据，整份 INT8 求值与完整写事务由本设计估算。

共同任务为  $128 \times 128$  INT8 矩阵乘 INT8 向量， $b_S = b_R = 1$  Byte/元素。每次输入  $B_S = 128$  Byte, resident 逻辑容量 16384 Byte, 输出为  $128 \times 24$  bit。边界含同一份矩阵的阵列、局部驱动、感测、数字归约及输出寄存器；独立服务单元和更新域均为一。数字路线在二进制状态正确读出、写入被接受的前提下给出精确整数结果。位切片、内部读回与正负两相写入不扩大逻辑 payload。

| 本地来源     | 原文证据及在本例的作用                                                                                                                                                                         |
|----------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| FENOR-02 | 2026 VLSI: SL-HZO + O-poor IGO 下 $\pm 2$ V、20 ns switching; Fig.3(d) 标注 RAWD < 100 ns; Fig.9 提供 $V_w/3$ 邻层方案和最高 $2V_w/3$ 半选扰动; Fig.10 实际验证 $4 \times 16 \times 16$ cell。作为主器件与选通依据。 |
| FENOR-01 | 2025 VLSI: $8 \times 8 \times 3$ NOR-type 阵列; $+4.25/-3.25$ V、50 ns; Fig.12 示意横向多个 cell 组成多位权重，配 SA、寄存器与加法器。用于数字计算机制桥接，未将其延迟或电压嫁接为 2026 阵列实测值。                                      |
| FENOR-04 | 2025 TED: 另一团队 ZnO/MFMIS; 两 cell 电流求和实测与 $4096 \times 4096$ 网络 / 外围模拟分开。其 500 ns 多级脉冲和栅堆栈不能替换主模式的二状态更新。                                                                             |
| FENOR-06 | 2026 EDTM: MFS/MFIS/MIFS/MIFIS 的 switching 约为 0.25/1.5/2/5 $\mu s$ , 终点为最大窗口的 90%。说明不同栅堆栈、偏置和终点必须保留，不能用一个“FeNOR 写速”覆盖所有状态。                                                          |

表 1: 证据互补方式; 页码、图号、原偏置和版本见证据笔记。

主模式选择 6 nm SL-HZO、4 nm O-poor IGO，并采用 O-0.1s 工艺的扰动抑制条件。原文分别展示了这些优化方向，本例将其作为工艺相容的参考条件，未宣称已测完整 CMOS 宏。FENOR-01/02/06 属同团队，不能算三份独立验证。尤其，FENOR-02 的制造尺寸  $4 \times 32 \times 32$ 、图案验证尺寸  $4 \times 16 \times 16$  与 Fig.11 的层数扩展仿真不是同一证据层级。

## 2 同一份矩阵的物理映射与完整求值

### 2.1 四层装容量，横向读通路提供并行

每个 INT8 权重使用八个二状态 cell，补码最高位取权  $-2^7$ 。构造 32 条独立的横向行读通路，每条使用四层存放四个输入索引；各层共享相应 BL/SL 时，每次只选一个层。每条行通路有 64 个局部条带：八个输出组乘八个位平面。每条带为四层、每层 16 个 BL/SL 列对，容量 64 cell。物理地址为

$$W_{o,i}[b] \mapsto (i \bmod 32, \lfloor i/32 \rfloor, 8\lfloor o/16 \rfloor + b, o \bmod 16).$$

四个坐标依次是横向行通路、层、条带和列。总容量

$$32 \times 64 \times (4 \times 16) = 131072 \text{ binary cell} = 16384 \text{ 逻辑 Byte}.$$

这是一种分段、局部选通的参考布局，采用原文竖直 BL/SL、横向 WL 和分层选择关系；原文没有流片本布局。16 列是与已测阵列尺度相接的工程条带宽度，并非该介质不可越过的上限。

读侧保留共同 R0 的 32 项、16 输出、8 权重 bit 并行：每条横向通路配置 128 个感测节点，合计  $32 \times 16 \times 8 = 4096$  个二进制感测节点，八组输出复用这些节点。32 条通路各有独立层选择与局部偏置，故可在一轮获得 32 项操作数。**若只给一组共享 BL/SA，就不能使用这里的 32 项并行计数。**四层并未变成四个独立服务副本，也没有额外乘四的吞吐收益。

本例先感测二进制权重，再与该轮输入 bit 做局部数字乘法，避免假设多层电流可以分别判为多个数字操作数。未选层需由关断偏置保持隔离，并在实际阈值分布下验证泄漏裕量。提供 16 条数字输出通道、32 项归约、八个权重位权合并和部分寄存器；每轮一拍完成相应 R0 数字功能。无跨输入位缓存复用，每轮重新读取。

### 2.2 读预算与共同外围的分工

一次完整二进制读侧响应  $t_m$  包含局部层 / 输出选择、偏置和 RC 建立、感测及恢复，选择短 / 参考 / 长为 20/40/80 ns。FENOR-02 Fig.5(c) 的  $-0.5 \text{ V}$ 、20 ns 是读耐久应力波形；Fig.11(d) 的读延迟由 TCAD 提取 RC 后在 SPICE 中模拟。两者支持数十 ns 的量级预算，均不能直接称为上述 4096 节点的完整实测读周期。移植后的负载、SA 裕量及层关断能力是预算成立条件。

共同 JSON 给出  $T_D = 2/5/10 \text{ ns}$ ；数字路线不使用 ADC，也不再叠加 ACIM 的  $T_I, T_A$ 。输入逐 bit，权重八位并行，故

$$N_D = N_{rd} = 8 \times (128/32) \times (128/16) = 256, \quad \boxed{\Delta_S = 256(t_m + T_D) + 2T_D}.$$

边界两拍覆盖输入接收和结果提交。各轮顺序执行，未引入流水隐藏时间；完整参考求值为  $256(40 + 5) + 10 = 11530 \text{ ns}$ 。

### 3 写入的行列选通、半选与有效更新粒度

主更新事务固定一个输入索引及连续 16 个输出，完成 16 个 INT8 权重，即  $B_R = 16$  Byte。128-bit 编码数据装入一个缓冲；单个写域一次只驱动一个 16-cell 条带，八个位平面依次更新。实际写并行来自 16 个可掩码 BL/SL 列对和四层 WL 偏置驱动，并非由 128-bit 接口自动产生。

#### 3.1 从原文单目标偏置到同极性多列掩码

FENOR-02 Fig.9(a) 使目标栅沟道差为  $V_w$ ，相邻 WL 差为  $V_w/3$ 。令  $s = +1$  或  $-1$ ， $V_w = 2$  V；本例将同极性的多个目标列接到相同电位，其他列被抑制：

| cell 类别 | WL 电位     | BL=SL 电位  | 栅沟道差      |
|---------|-----------|-----------|-----------|
| 本层本相目标  | $2sV_w/3$ | $-sV_w/3$ | $sV_w$    |
| 本层被掩码列  | $2sV_w/3$ | $+sV_w/3$ | $sV_w/3$  |
| 其他层、目标列 | $sV_w/3$  | $-sV_w/3$ | $2sV_w/3$ |
| 其他层、抑制列 | $sV_w/3$  | $+sV_w/3$ | 0         |

表 2: 同一局部条带的写电压表。正负相分别取反；其他独立条带保持停驻。

先用正相对目标 bit 1 施加 +2 V、20 ns，再用负相对目标 bit 0 施加 -2 V、20 ns。已在第一相写成 1 的列，在第二相只承受  $-V_w/3$ ，不是一次全幅反写。不同层的半选最大为  $2V_w/3$ ，邻层 WL 差仍为  $V_w/3$ 。两相均有非空目标的普通混合字决定服务预算；不以全 0 / 全 1 跳过一相来构造峰值。

该多列掩码方案保留原图的每 cell 电场分类；它是需要相应扇出和供电的工程扩展，原文没有给出其 16 列并发写波形。Fig.9(b) 在  $2V_w/3$  扰动下展示两种状态至  $10^9$  次未见明显变化；Fig.9(c,d) 在 40 nm 垂直节距下将 C2C 阈值扰动控制到约 50 mV 内。这些结果支持采用上述有限局部选通条件，不能证明任意工艺、任意脉冲尾沿或无限重复都无扰动。

#### 3.2 任意目标状态和矩阵聚合

极化的正负写入分别直接建立两个终态；这里不需要闪存块擦除，也不先把所有 cell RESET 再逐一 SET。两个掩码相是任意混合目标字的构造步骤，不是每个 cell 必须经过两次全幅切换。terminal verify 检查该条带的全部 16 cell，之后才宣布可用；一次 16-Byte 事务在八个位平面都通过后完成。失败被报告为异常，本例未凭空指定重试次数或成功率。

矩阵包含  $128 \times (128/16) = 1024$  个上述对齐事务；完整重载顺序聚合全部 1024 次命令、脉冲、guard 和 verify。它们均更新本矩阵有效字节，故总 payload 为 16384 Byte，时间同比增加， $\tau$  不变。稀疏、非对齐更新须按实际完成的权重数重算有效粒度，不能沿用 16 Byte 分子。

## 4 从 20 ns 脉冲到完整可计算状态

### 4.1 有限的驱动、写后观察和读回预算

专用偏置转换取  $t_e = 5/10/20$  ns, 覆盖局部选通、电平转换和所选电位建立。这是明确的电路预算, 原文没有实测此驱动。为使量级可审查, 选择每个被驱动局部节点有效负载不超过 100 fF, 最大电位摆幅  $8/3$  V, 则参考 10 ns 边沿需要

$$I \geq C\Delta V/t_e = 100 \text{ fF} \times (8/3) \text{ V} / (10 \text{ ns}) \simeq 26.7 \mu\text{A}.$$

参考配置每分支提供至少  $30 \mu\text{A}$  瞬态能力; 16 BL、16 SL 与四个 WL 节点共 36 个分支, 约 1.08 mA 的总瞬态驱动能力。短 / 长情景相应取每分支 60/15  $\mu\text{A}$ 。Fig.11 的模型横向节距 120/170 nm 对应 16 列约 2–3  $\mu\text{m}$ , 四层按实测 40 nm 节距约 160 nm 高, 支持采用短局部条带而非长全局线的设计。100 fF 是这种尺度下待版图验证的负载目标, 不是文献提取值;  $C\Delta V/I$  检查也不构成驱动验证。局部偏置轨已就绪, 未把电源冷启动藏入器件脉冲。实际负载更大时须增加驱动或延长  $t_e$ 。

20 ns 只作为每个极性的电场平台宽度。最后一相脉冲结束后, 采用  $g = 100$  ns 的写后观察窗口, 再发起终态二进制读回。依据是 Fig.3(d) 的 RAWD < 100 ns; **100 ns 是本例保守观察窗口, 不是实测必须等待的常数, 也不意味着原文测得零延迟**。最后的偏置退回放在这 100 ns 之内, 不另叠一次恢复。第一相与第二相之间的退回另需一个  $t_e$ 。

每批严格按“建立正相、正脉冲、退回、建立负相、负脉冲、写后窗口、二进制读回、比较”顺序执行。因此, 若一批比较占  $k_v$  拍,

$$t_{\text{batch}} = 3t_e + 2t_p + \max(g, t_e) + t_m + k_v T_D.$$

主情景  $t_p = 20$  ns、 $g = 100$  ns、 $k_v = 1$ , 使用与 streaming 相同的二进制感测响应  $t_m$ 。16 路比较器一拍检查 16 cell; 读回用既有读资源, 无 ADC / 数字比较重复收费。

### 4.2 完整时间账本与终点

共同接口按一批数据与命令同拍,  $T_{\text{front}} = 2T_D$ 。八批物理更新后才完成 16 Byte, 因此

$$\Delta_R = 2T_D + 8(3t_e + 40 + 100 + t_m + T_D).$$

| 参考事务的占用        | 次数与单项                  | 总时间 (ns) |
|----------------|------------------------|----------|
| 接口 / 完成控制      | $2 \times 5$           | 10       |
| 两次建立及相间退回      | $8 \times 3 \times 10$ | 240      |
| 正负极化平台         | $8 \times 2 \times 20$ | 320      |
| 最后脉冲后窗口 (已含退回) | $8 \times 100$         | 800      |
| 终态读回           | $8 \times 40$          | 320      |
| 16 路比较         | $8 \times 5$           | 40       |
| 完整 16-Byte 写服务 |                        | 1730     |

表 3: 每项只计一次。最后窗口结束并读回 / 比较通过, 才是 resident 可计算终点。

## 5 配对结果、结构对照与适用边界

按共享 API 计算  $\rho = B_S/\Delta_S$ 、 $\tau = B_R/\Delta_R$ 、 $RI^* = \rho/\tau$ ；Byte/ns 的数值等于十进制 GB/s。参考点手算为

$$\rho = \frac{128}{11530} = 0.01110 \text{ GB/s}, \quad \tau = \frac{16}{1730} = 0.009249 \text{ GB/s},$$

$$RI^* = \frac{128}{16} \frac{1730}{11530} \simeq 1.200.$$

| 情景             | $\Delta_S$ (ns) | $\Delta_R$ (ns) | $\rho$ (GB/s) | $\tau$ (GB/s) | $RI^*$ |
|----------------|-----------------|-----------------|---------------|---------------|--------|
| 短              | 5636            | 1420            | 0.02271       | 0.01127       | 2.0156 |
| 参考             | 11530           | 1730            | 0.01110       | 0.00925       | 1.2003 |
| 长              | 23060           | 2340            | 0.00555       | 0.00684       | 0.8118 |
| 参考, 128-cell 写 | 11530           | 260             | 0.01110       | 0.06154       | 0.1804 |

表 4: 同一二状态映射的配对结果。主情景每批 16 cell；最后一行增加八倍写驱动资源，另列为结构对照。

主情景的配对范围为  $\rho \approx 0.00555\text{--}0.02271$  GB/s、 $\tau \approx 0.00684\text{--}0.01127$  GB/s， $RI^* \approx 0.812\text{--}2.016$ 。三组分别配共享短 / 参考 / 长外围以及本例读响应、偏置建立预算，是有条件情景范围，非置信区间或整个技术族的材料界。长情景中读侧相对写侧下降更多，故 ridge 随之减小；不能据此称两路变化普遍抵消。

### 5.1 只改变物理写资源的对照

保持同一容量、读侧、接口和单域控制，把八个字的八个位平面条带同时驱动：物理并行由 16 增至 128 cell，需要八组条带的 WL 驱动、128 个可掩码 BL/SL 列对及约八倍瞬态供电。参考每分支 30  $\mu\text{A}$ 、288 个节点合计约 8.64 mA；能否维持 10 ns 边沿须经实际电路验证，不能由数据接口推定。

读回并行使用该行通路已有的 128 个 SA，比较仍只有 16 路，所以需八拍。完整服务变为

$$\Delta_{R,128} = 10 + 3(10) + 2(20) + 100 + 40 + 8(5) = 260 \text{ ns}.$$

$B_R$  仍为 16 Byte， $\rho$  不变； $\tau$  提高约 6.65 倍、ridge 降为 0.1804。这个变化来自可同时服务的实际写驱动和选通资源，不是层数增加，也不是器件 pulse 变快。其结果仅为资源有条件的对照，不取代主情景。

### 5.2 主导项与未被数字消除的限制

参考读侧的 256 次物理读占  $10240/11530 \approx 88.8\%$ ；参考写侧的写后窗口占  $800/1730 \approx 46.2\%$ ，极化平台只占约 18.5%。每批额外需要 10 ns 写后窗口，整事务增加 80 ns，固定读侧时 ridge 增加约 4.62%。这比把 20 ns 直接作写服务周期更能说明本例的不确定性来源。完整矩阵重载为  $1024 \times 1730 = 1.77152 \text{ ms}$ ，仍是相同  $\tau$ 。

本局部服务窗口不安排周期 refresh 或破坏性读后 restore。原文写耐久  $> 10^{12}$ 、读应力耐久  $> 10^{12}$ 、半选耐受  $10^9$  以及约 3000 s 保持测量 / 十年外推是不同条件；不能把它们合成全阵列、全寿命的无错承诺。半选累计、长读脉冲尾沿、工艺兼容性和阈值裕量需另作可靠性评估，不将寿命直接折算为瞬时  $\tau$ 。两路共用局部状态与感测 / 控制资源，表中分别服务能力不保证同时达到峰值。

## 6 复核人口与结论的证据边界

本例得到的是具有明确横向读资源、有限写条带及写后终点的二状态数字参考实现。决定局部服务的量不止铁电切换脉冲：读侧需完成 256 轮感测和数字归约；写侧需完成八个位平面、两相掩码、偏置恢复、观察窗口及读回比较。四层仅承载相应 resident 容量。结果没有预设 FeNOR 必须最优，也未据来源文中的 LLM 应用描述推导 workload 匹配性。

### 6.1 原始文献定位

以下均按本地 PDF 页序；两篇 VLSI 的本地版本为用户提供的三页稿件，无文件内版本 / 日期标识。

1. **FENOR-02**: Y. Zhou 等, *3D Vertical FeFET Array with Record Endurance ( $> 10^{12}$ ), Fast Writing ( $\pm 2V$ , 20 ns), Disturb Immunity, and Kb-scale Verification for High Density 1T RAM*, VLSI 2026. p.1 结构与工艺; p.2 Figs.2–5 的尺寸、脉冲、RAW、耐久; p.3 Figs.7–10 的半选、C2C 与图案验证; Fig.11 是 TCAD/SPICE。DOI: [10.1109/VLSITechnologyandCir65830.2026.11577291](https://doi.org/10.1109/VLSITechnologyandCir65830.2026.11577291)。
2. **FENOR-01**: Y. Zhou 等, *3D NOR-type FeFETs with Record Endurance of  $10^{11}$ , Fast Erase of 50 ns, and Immediate Read-After-Write for In-Memory Learning*, VLSI 2025. p.2 Figs.2–5; p.3 Fig.12 的二进制逻辑测量与数字结构。DOI: [10.23919/VLSITechnologyandCir65189.2025.11074820](https://doi.org/10.23919/VLSITechnologyandCir65189.2025.11074820)。
3. **FENOR-04**: Y. Feng 等, *Efficient Large Scale Neural Network Acceleration With 3-D FeNOR-Based Computing-in-Memory Design*, IEEE TED 72(5), 2025. p.4 Figs.7–8 的电压、窗口及可靠性; p.5 Figs.9–11 的脉冲与两 cell 求和; pp.5–6 的大阵列模型。DOI: [10.1109/TED.2025.3554164](https://doi.org/10.1109/TED.2025.3554164)。
4. **FENOR-06**: Y. Zhou, R. Huang, K. Tang, *Gate Stack Engineering of 3D Oxide Channel FeNOR Memory with High-Speed and Reliability*, EDTM 2026. p.2 Sec.II-C 的 90% 终点; p.3 Figs.8–10 的四种栅堆栈速度与可靠性。DOI: [10.1109/EDTM65772.2026.11498024](https://doi.org/10.1109/EDTM65772.2026.11498024)。

### 6.2 可复算性与待主审条件

`data/inputs.json` 将原值、工程选择、映射、阶段覆盖和资源对照分开; `data/results.json` 保留全部未取整结果、计数及共享 JSON / API 的 SHA-256。 `scripts/check_fenor.py` 直接导入共享 API，不复制共同常数与吞吐公式；默认只读，`--emit` 才刷新结果和表格。检查覆盖所有 131072 cell 的唯一映射、正负偏置表、两路配对、阶段账本、整矩阵聚合和来源哈希。

主审重点是四项条件是否与希望比较的参考资源一致：4096 个独立感测节点的物理代价；SL + O-poor 与 O-0.1s 的组合条件；16 列多目标掩码下的负载 / 扰动；100 ns 写后观察窗口和一次终态 verify 是否足够。它们已通过有限预算进入结果，未用缺少完整实测宏作为拒绝估算的理由；也未以计算检查代替这些电路与器件条件的实验验证。