

一次装载与复用次数的 RI

2026 年 10 月 2 日

1 对象与公式

设权重矩阵 $W \in \mathbb{R}^{N \times K}$ ，其中 N 为输出维度、 K 为输入维度。权重完整装载一次后，累计服务 U 个输入向量。这里统一把 U 称为**复用次数 (reuse count)**，包含首次使用；它可跨多个 batch 或请求累计，直到这份权重被替换或重新装载。

将这些向量按行记为 $X \in \mathbb{R}^{U \times K}$ ，则 $Y = XW^T \in \mathbb{R}^{U \times N}$ 。这只是累计计数的矩阵写法，不要求 U 个向量同时组成一次 batch。输入与权重均按每元素 1 Byte，在算子入口计入每个输入元素一次：

$$Q_S = UK, \quad Q_R = NK, \quad \text{RI} = \frac{Q_S}{Q_R} = \frac{U}{N}.$$

Q_S 是累计 streaming 输入量， Q_R 是本窗口的累计权重写入量；输出 Y 不另加进 Q_S 。本表不需要任何硬件尺寸参数。

2 矩阵与代入结果

下表使用五种逻辑矩阵形状，扫描一次装载后的复用次数。所有结果由 Python 的整数与精确分数计算，小数取整只用于展示。

表 II(a): 五种逻辑权重矩阵在不同复用次数下的 RI

权重形状 $N \times K$	$U = 1$	$U = 128$	$U = 1\text{K}$	$U = 16\text{K}$	$U = 128\text{K}$	$U = 1\text{M}$	$U \rightarrow \infty$
128×128	0.00781	1.0	8.0	128.0	1024.0	8192.0	∞
$1\text{K} \times 1\text{K}$	0.000977	0.125	1.0	16.0	128.0	1024.0	∞
$4\text{K} \times 4\text{K}$	0.000244	0.0313	0.250	4.0	32.0	256.0	∞
$1\text{K} \times 4\text{K}$	0.000977	0.125	1.0	16.0	128.0	1024.0	∞
$4\text{K} \times 1\text{K}$	0.000244	0.0313	0.250	4.0	32.0	256.0	∞

1K = 1024, 1M = 1024²；直立 K/M 是数量后缀，斜体 K 是矩阵输入维度。RI 至少为 1 时保留一位小数，小于 1 时保留三位有效数字；精确值保存在机器数据中。末列为一次装载的无界复用极限，写入量仍为有限的 NK Byte。

3 结果说明

固定 N 时，RI 随 U 线性增长； $U = 1$ 时为 $1/N$ 。 $U \rightarrow \infty$ 是无界复用极限： Q_S 无界增长，而一次写入量 $Q_R = NK$ 保持有限。这里没有无穷大的实际 batch，也没有把有限窗口的写入量改成零。

相同 N 的矩阵具有相同 RI：改变 K 同时缩放输入量和权重写入量，比例中恰好抵消。例如 $U = 1\text{K}$ 时， $1\text{K} \times 4\text{K}$ 与 $4\text{K} \times 1\text{K}$ 两矩阵均写入 4 MiB 权重，输入分别为 4 MiB 与 1 MiB，RI 分别为 1.0 与 0.250。1 MiB = 2²⁰ Byte。

后续 II(b) 沿用此记号与输入边界：同一矩阵阶段的共同源输入只计一次，后续矩阵阶段的新输入另计。QKV 与 FFN 用 U 表示权重复用次数；Attention 用 L 表示可见序列长度，并按其状态更新窗口累计。

精确字节、原始分数与复算入口见本目录 README 和 data/。