

QKV 投影的输入复用与 RI

2026 年 10 月 2 日

1 对象与公式

取每个模型的一层完整 / 全局 GQA。将 Q、可选的输出门控 G、K、V 投影权重完整装载一次，累计服务 U 个输入向量。沿用 II(a) 的复用次数 (reuse count): 包含首次使用, 可跨多个 batch 或请求累计。输入与权重均按每元素 1 Byte 计数。各投影使用同一个 $X \in \mathbb{R}^{U \times D}$, 权重形状为 $W_j \in \mathbb{R}^{N_j \times D}$, 输出为 XW_j^T 。本对象到这组投影结束, 不包含后续 O 投影。

原生 query 与 KV 头数分别为 H_q, H_{kv} , 每头 QK 与 V 维度为 d_{QK}, d_V ; 额外门控宽度为 D_g , 未启用时取 0。于是

$$\begin{aligned} N_Q &= H_q d_{QK}, & N_G &= D_g, \\ N_K &= H_{kv} d_{QK}, & N_V &= H_{kv} d_V, \\ N_{\text{proj}} &= N_Q + N_G + N_K + N_V. \end{aligned}$$

同一矩阵阶段的共享输入只计一次; 各权重写入相加。沿用 Table II(a) 的一次装载口径, 得到

$$Q_S = UD, \quad Q_R = DN_{\text{proj}}, \quad \text{RI} = \frac{Q_S}{Q_R} = \frac{U}{N_{\text{proj}}}.$$

若共有 m 个投影分项, 逐项独立记录时各有 $Q_S^{(j)} = UD$ 、 $Q_R^{(j)} = DN_j$; 汇总输入需扣除 $(m-1)UD$ 的同源重叠。投影输出不直接加入本阶段的 Q_S 。

2 模型信息

下表列出固定层的原生投影宽度; 层号从 0 起, 所有矩阵的输入维度均为 D 。 $N_G = 0$ 表示没有额外 G 投影。

模型	层号	D	N_Q	N_G	N_K	N_V	N_{proj}
Qwen3.5-2B	3	2048	2048	2048	512	512	5120
Ministral 3 8B (2512)	0	4096	4096	0	1024	1024	6144
Qwen3.6-35B-A3B	3	2048	4096	4096	512	512	9216
Tencent Hy3 (295B)	1	4096	8192	0	1024	1024	10240
Ling-1T	4	8192	8192	0	1024	1024	10240
MiMo-V2.5-Pro	7	6144	24576	0	1536	1024	27136

两款 Qwen 的原生 `q_proj` 同时产生 Q 与 G, 表中分别保留其逻辑宽度。MiMo 的 $d_{QK} = 192$ 、 $d_V = 128$, 故 K 与 V 的宽度不同; 其余五款的 QK 与 V 每头维度相同。固定版本与原始实现的定位保存在机器配置中。

3 代入结果

表内为小数 RI；前四列为 $U \in \{1, 1K, 128K, 1M\}$ ，末列为无界复用极限。

模型	$U = 1$	$U = 1K$	$U = 128K$	$U = 1M$	$U \rightarrow \infty$
Qwen3.5-2B	0.000195	0.200	25.6	204.8	∞
Ministral 3 8B (2512)	0.000163	0.167	21.3	170.7	∞
Qwen3.6-35B-A3B	0.000109	0.111	14.2	113.8	∞
Tencent Hy3 (295B)	0.0000977	0.100	12.8	102.4	∞
Ling-1T	0.0000977	0.100	12.8	102.4	∞
MiMo-V2.5-Pro	0.0000369	0.0377	4.8	38.6	∞

1K = 1024, 1M = 1024²。RI 至少为 1 时保留一位小数，小于 1 时保留三位有效数字；精确值见机器数据。

例如 Qwen3.5-2B 在 $U = 1K$ 时，

$$\begin{aligned}
 N_{\text{proj}} &= 2048 + 2048 + 512 + 512 = 5120, \\
 Q_S &= 1024 \times 2048 = 2\,097\,152 \text{ Byte}, \\
 Q_R &= 2048 \times 5120 = 10\,485\,760 \text{ Byte}, \\
 \text{RI} &= \frac{2\,097\,152}{10\,485\,760} = 0.200.
 \end{aligned}$$

4 结果说明

固定模型时， U 每增加一倍， Q_S 与 RI 都增加一倍，而一次权重写入量 Q_R 不变。 $U = 1$ 是这份装载只服务一个向量的端点； $U \rightarrow \infty$ 时，输入量与 RI 无界增长，但 Q_R 始终为有限的 DN_{proj} ，有效权重容量也保持该值。

跨模型比较由所选投影的总输出宽度 N_{proj} 决定。Hy3 与 Ling 的 N_{proj} 都为 10240，因而各档 RI 相同；Ling 的 D 是 Hy3 的两倍，绝对输入与权重字节也都翻倍，比例恰好抵消。模型的总参数标签不能替代这组投影尺寸。

额外 G 投影增加权重写入量，却继续共享同一份输入，因此必须计入 N_{proj} 。MiMo 的原生 Q/K/V 总宽度为 27136，是本组六款中最大的，故相同 U 下 RI 最小；这一差别来自实际头数及头维，而非模型名称或输入维度 D 本身。

固定模型来源、精确字节及复算记录见本目录 README 与 data/；数学入口为 Table II(a)。