

六模型 FFN 与单路由专家

一次装载、实际向量复用与双边界需求

2026 年 9 月 25 日

结论：六模型的 ports RI 均为 $B/128$ ；相同 RI 不意味着相同容量或总需求。在 $B = (8, 64, 512)$ 下，三档值均为 $(1/16, 1/2, 4)$ 。六个固定模型、每模型三个窗口共 18 个工况；54 个矩阵分项已由原始配置和独立 tile 求和复算，6 个 pilot 重叠工况逐字段一致。

1 实际分析对象与六模型概览

每个窗口只装载一个 Dense FFN 或一个路由专家的 gate、up、down 三矩阵各一次。 B 是这同一份权重驻留期间**实际服务的向量总数**，不是批次数，也不自动等于全局 batch size。所选层号从 0 起，不乘 top-k、路由专家总数、共享专家数或层数。

模型	层	对象	D	F	$3DF$ (MiB)	tiles
Qwen3.5-2B	3	Dense	2048	6144	36	2304
Ministral 3 8B	0	Dense	4096	14336	168	10752
Qwen3.6-35B-A3B	3	单专家	2048	512	3	192
Hy3 (295B)	1	单专家	4096	1536	18	1152
Ling-1T	4	单专家	8192	2048	48	3072
MiMo-V2.5-Pro	7	单专家	6144	2048	36	2304

Ministral 完整版本为 Ministral 3 8B Base 2512；Hy3 为 Tencent Hy3 (295B)。容量单位 1 MiB = 2^{20} Byte。表中 tiles 是三语义 bank 的总驻留 tile 数。

为什么选这些宽度 Qwen3.5 与 Ministral 取 Dense 宽度；其余取 `moe_intermediate_size`。Hy3 第 1 层使用 $F = 1536$ ，不是第 0 层 Dense 的 13312；Ling 第 4 层使用 2048，不是前四层 Dense 的 18432；MiMo 第 7 层使用 2048，不是第 0 层的 16384。Qwen3.6 单专家宽 512；其共享专家是另一个对象。原生路由器与 SwiGLU gate 也不是同一矩阵。

模型	gate / up 的 $N \times K$	down 的 $N \times K$	单矩阵 tiles
Qwen3.5-2B	6144×2048	2048×6144	768
Ministral 3 8B	14336×4096	4096×14336	3584
Qwen3.6-35B-A3B	512×2048	2048×512	64
Hy3 (295B)	1536×4096	4096×1536	384
Ling-1T	2048×8192	8192×2048	1024
MiMo-V2.5-Pro	2048×6144	6144×2048	768

固定计量参考 沿用 WS128-INT8-semantic-banks-v1: 128×128 tile，所有操作数角色每元素 1 Byte，gate、up、down 各自独立分块并同期驻留。原生 BF16 或 FP8 mixed 声明仍保留在配置来源中；这里的 INT8 是逻辑参考，不是六模型精度验证。所有六组 D, F 均整除 128，当前 FFN 没有尾块，有效容量恰等于完整 tile 槽位容量。

2 从三矩阵到两种输入边界

记 $W_g, W_u \in \mathbb{Z}^{F \times D}$, $W_d \in \mathbb{Z}^{D \times F}$,

$$z = \text{SiLU}(W_g x) \odot (W_u x), \quad y = W_d z. \quad (1)$$

gate/up 收到同一输入 x ；数字域的 SiLU、逐元素乘积和重定标产生 down 的新输入 z 。当前矩阵的输出不再另加一次 streaming payload； z 在 down 真正接收时计数。tile 部分和的数字累加也不重新作为矩阵输入计入。

分项及汇总 ports 在各 tile 接收端累计，operator 在整矩阵阶段入口计数。下表 operator 分项均为独立入口值，三项直接相加会重复计 gate/up 的 BD 。

分项	Q_S^{op} (Byte)	Q_S^{ports} (Byte)	Q_R (Byte)	调用数
gate	BD	$B \lceil F/128 \rceil D$	DF	$B \lceil F/128 \rceil \lceil D/128 \rceil$
up	BD	$B \lceil F/128 \rceil D$	DF	$B \lceil F/128 \rceil \lceil D/128 \rceil$
down	BF	$B \lceil D/128 \rceil F$	DF	$B \lceil D/128 \rceil \lceil F/128 \rceil$

因此两个边界分别得到

$$Q_S^{\text{op}} = (BD + BD + BF) - BD = B(D + F), \quad (2)$$

$$Q_S^{\text{ports}} = B(2 \lceil F/128 \rceil D + \lceil D/128 \rceil F), \quad Q_R = 3DF, \quad (3)$$

$$C = 3B \lceil D/128 \rceil \lceil F/128 \rceil. \quad (4)$$

每个 RI 都从对应边界的累计字节求商。operator 分项 RI 为 gate/up 的 B/F 和 down 的 B/D ；汇总 RI 为 $B(D + F)/(3DF)$ ，不能直接平均这些分项 RI。

相同比例的抵消条件 本轮 D, F 都整除 128，且所有 streaming / resident 角色等宽、每矩阵仅装载一次，故

$$Q_{S,g}^{\text{ports}} = Q_{S,u}^{\text{ports}} = Q_{S,d}^{\text{ports}} = \frac{BDF}{128}, \quad \text{RI}^{\text{ports}} = \frac{3BDF/128}{3DF} = \frac{B}{128}. \quad (5)$$

这依赖当前 bank 映射、边界和驻留窗口。若行维不整除 128、角色精度不等、发生额外重载或改用其它输入边界，应回到未约简式；相同 RI 不是必须人为打破的结果。

完整字节量的紧凑表达 下表列出常量系数，可对每一行分别代入 $B = 8, 64, 512$ ，得到全部 18 工况。前三数值列单位均为 Byte， C 为实际逻辑 tile 求值调用数。

模型	Q_R	Q_S^{ports}/B	Q_S^{op}/B	C/B
Qwen3.5-2B	37748736	294912	8192	2304
Ministral 3 8B	176160768	1376256	18432	10752
Qwen3.6-35B-A3B	3145728	24576	2560	192
Hy3 (295B)	18874368	147456	5632	1152
Ling-1T	50331648	393216	10240	3072
MiMo-V2.5-Pro	37748736	294912	8192	2304

Q_R 与容量当前数值相同，因为窗口从装载开始，只有一次完整写入；二者仍分字段保存。槽位容量不代表介质编码后容量；调用数也不是单个 macro 的时钟周期或执行时间。

3 尺寸、专家粒度与驻留复用分别改变什么

完整代入：Qwen3.6 单专家, $B = 8$ 第 3 层取 $D = 2048, F = 512$; gate/up 为 512×2048 , 各分为 $4 \times 16 = 64$ tiles, down 为 2048×512 , 分为 $16 \times 4 = 64$ tiles。gate/up 每项 ports 输入为 $8 \times 4 \times 2048 = 65536$ Byte, down 为 $8 \times 16 \times 512 = 65536$ Byte; 各项写入 $512 \times 2048 = 1048576$ Byte, 各调用 $8 \times 64 = 512$ 次。汇总调用 1536 次, 并得

$$RI^{\text{ports}} = \frac{3 \times 65536}{3 \times 1048576} = \frac{196608}{3145728} = \frac{1}{16}. \quad (6)$$

operator 的独立 gate/up 入口各为 $8 \times 2048 = 16384$ Byte, down 为 $8 \times 512 = 4096$ Byte。扣除同源重叠 16384 Byte 后, $Q_S^{\text{op}} = 16384 + 16384 + 4096 - 16384 = 20480$ Byte, 即 $8(2048 + 512)$; 同一次写入量下, $RI^{\text{op}} = 20480/3145728 = 5/768$ 。

operator 保留尺寸差异 operator 没有向输出 tile 分发的乘数, 故 RI 依赖 D, F 。以下保持固定模型顺序, 所有分数由精确字节相除得到。

模型	$B = 8$	$B = 64$	$B = 512$
Qwen3.5-2B	$\frac{1}{576}$	$\frac{1}{72}$	$\frac{1}{9}$
Ministral 3 8B	$\frac{3}{3584}$	$\frac{3}{448}$	$\frac{3}{56}$
Qwen3.6-35B-A3B	$\frac{5}{768}$	$\frac{5}{96}$	$\frac{5}{12}$
Hy3 (295B)	$\frac{11}{4608}$	$\frac{11}{576}$	$\frac{11}{72}$
Ling-1T	$\frac{5}{3072}$	$\frac{5}{384}$	$\frac{5}{48}$
MiMo-V2.5-Pro	$\frac{1}{576}$	$\frac{1}{72}$	$\frac{1}{9}$

专家粒度改变总量 Ministral Dense 的三矩阵为 168 MiB, Qwen3.6 单路由专家为 3 MiB, 前者是后者的 56 倍。固定 B 后, ports 输入、写入、驻留 tiles 和调用数也都相差 56 倍。例如 $B = 64$: 两者 ports 输入为 84/1.5 MiB, 写入为 168/3 MiB, 调用为 688128/12288 次; RI 均为 1/2。这一对比只比较所选 FFN / 单专家, 不能据模型总参数标签推断全模型需求。

交换 D, F , 汇总相同而分项不同 Qwen3.5 的 $(D, F) = (2048, 6144)$ 与 MiMo 的 $(6144, 2048)$ 互换。本轮对齐条件下, 两者 ports 分项与汇总、 Q_R 、容量、tiles 和调用都相同。operator 汇总也相同, 因为 $D + F$ 和 DF 都不变; 但独立入口与重叠扣除不同。以下固定 $B = 64$, 单位为 KiB, 1 KiB = 1024 Byte。

模型	gate	up	down	扣除同源重叠	汇总 Q_S^{op}
Qwen3.5-2B	128	128	384	128	512
MiMo-V2.5-Pro	384	384	128	384	512

每模型 ports 输入均为 18 MiB, 写入与容量均为 36 MiB, 调用均为 147456 次。因此只看汇总无法识别 gate/up 的入口差别; 机器数据保留全部分项和显式重叠量。MoE 标签本身也不保证所选单专家需求与 Dense 不同。

B 改变服务次数, 不改变一次装载量 从 $B = 8$ 到 64 再到 512, 两个边界的 Q_S 、RI 以及调用数每次均增至 8 倍。 Q_R 、容量与驻留 tiles 不变。三档 ports RI 跨过 1 仅表示窗口内累计输入与一次写入的字节关系, 不能据此宣称某种介质更快。若实际专家路由无法在驻留期间服务这么多向量, 应改变 B 或驻留策略; 本稿没有把路由均衡、命中率或 top-k 作为隐藏假设。

4 来源、独立回查与复现

固定版本的原始证据 六模型使用已通过 Step 1 的本地配置、实现和结构卡。下列链接指向固定 checkpoint revision；完整路径、URL、文件 SHA-256 与原生精度记录见 `data/config.json`。

- Qwen3.5-2B: [15852e8c16360a2fea060d615a32b45270f8a8fc](#)。
- Ministral 3 8B Base 2512: [d4883f9b36aa2e5d775730d3fdb3d30de51a8ef](#)。
- Qwen3.6-35B-A3B: [995ad96eacd98c81ed38be0c5b274b04031597b0](#)。
- Tencent Hy3: [a960ebc3da325ba167f069f76c41eb62c9280d22](#)。
- Ling-1T: [268f2aa76aa8cf5b36ca33805481cea91133327e](#)。
- MiMo-V2.5-Pro: [21d1ecfec7bd70f31be25ca49d7edd21f003659](#)。

矩阵来源的具体定位 前四模型共享 Transformers 实现固定于 2c4914f，位于 `literature/00_shared/raw/transformers/`。Qwen3.5 的 `Qwen3_5MLP` (824 行起) 和 Ministral 的 `Ministral3MLP` (176 行起) 明确给出三个线性层。Qwen3.6 的 `Qwen3_5MoeExperts` (845 行起) 以及 Hy3 的 `HYV3Experts` (311 行起) 先堆叠各专家，再打包 `gate/up`；逻辑切分仍是两个 $F \times D$ 矩阵。Hy3 官方转换代码 207–234 行也可对应这一打包。Ling 的 `BailingMoeV2MLP` (271 行起) 及专家列表 (367 行起)、MiMo 的 `MiMoV2MLP` (115 行起) 与专家列表 (182 行起) 保留独立三矩阵。后两实现分别位于各自 `literature/05_ling_1t/raw/` 和 `literature/06_mimo_v25_pro/raw/`。源码只做静态核对，没有执行模型或下载权重。

两条计算路径 主入口 `scripts/generate.py` 从任务根 `data/models.json` 的已审阅参数调用共享 FFN API。独立入口 `scripts/check.py` 重新读取六份原始 config，核对层型、revision、专家宽度与实现字面锚点；逐个真实 row/column tile 累加有效写入面积，并对每个向量、每个接收 tile 累加输入片长与调用。operator 通过 (x 或 z ，向量编号) 身份字典去重，不调用共享生产公式或主生成器。18 个工况全部通过；pilot 中 Ministral 和 Qwen3.6 的 6 个工况重新算后比较完整记录，一致。三个 B 下的 Qwen3.5/MiMo 转置对照也单独通过。

交付与命令 本目录为 `table_IIb/02_ffn_moe/`。精确结果见 `data/results.json / data/results.csv`，六模型概览见 `OVERVIEW.zh.md`，复核见 `data/checks.json`，页面 QA 见 `data/pdf_qa.json`。在本目录执行：

```
TASK2_PYTHON=/opt/anaconda3/bin/python sh scripts/build.sh
/opt/anaconda3/bin/python scripts/render.py
```

本轮保持 Step 1/2 和 pilot 原件，不开展硬件性能推算或 Step 5 英文总表。共享计数说明见任务根的 `shared/tex/counting_method.zh.tex` 第 5 节；本稿的生成与独立检查结果支持继续使用同一参考版本。