

FFN / MoE 的输入复用与 RI

2026 年 10 月 2 日

1 对象与公式

每个窗口取一个 Dense FFN 或一个路由专家，完整装载其 gate、up、down 三矩阵一次，随后累计服务 U 个向量。 U 为复用次数 (reuse count)，包含首次使用；可跨多个 batch 或请求累计。沿用 Table II(a) 的等宽口径，所有计数角色均为每元素 1 Byte。

设模型隐藏维为 D ，FFN / 单专家中间宽度为 F 。三矩阵及累计输入的关系为

$$W_g, W_u \in \mathbb{R}^{F \times D}, \quad W_d \in \mathbb{R}^{D \times F}, \quad X \in \mathbb{R}^{U \times D}, \\ Z = \text{SiLU}(XW_g^T) \odot (XW_u^T), \quad Y = ZW_d^T.$$

在矩阵阶段入口计数：gate/up 共用同一源输入 X ，只计 UD Byte； Z 是 down 的新输入，另计 UF Byte。因此，三个分项各自的输入为 UD, UD, UF ，汇总时扣除一次 UD 的共享重叠。

$$Q_S = U(D + F), \quad Q_R = 3DF, \quad \text{RI} = \frac{U(D + F)}{3DF}.$$

Q_S 与 Q_R 的单位均为 Byte，RI 为二者之比。初始有效权重容量为 0，末态保留三矩阵，容量为 $3DF$ Byte。当前输出不直接加进 Q_S ；若它成为下一矩阵阶段的输入，则在该阶段计数。这里的 gate 是 SwiGLU 分支，路由矩阵不在此对象内；单专家结果不乘 top-k、专家总数、共享专家数或层数。

2 模型信息

下表保留固定 checkpoint 的原生 D, F ，层号从 0 起。前两项取一个 Dense FFN，后四项取所选 MoE 层中的一个路由专家。

模型	所选对象	层号	D	F
Qwen3.5-2B	Dense FFN	3	2048	6144
Ministral 3 8B (2512)	Dense FFN	0	4096	14336
Qwen3.6-35B-A3B	单路由专家	3	2048	512
Tencent Hy3 (295B)	单路由专家	1	4096	1536
Ling-1T	单路由专家	4	8192	2048
MiMo-V2.5-Pro	单路由专家	7	6144	2048

3 代入结果

六模型各扫描 $U \in \{1, 16, 128, 1K, 16K\}$, 得到 30 个有限工况。表内为小数 RI; 三矩阵的一次写入量在同一模型的各项中保持不变。

模型	$U = 1$	$U = 16$	$U = 128$	$U = 1K$	$U = 16K$
Qwen3.5-2B	0.000217	0.00347	0.0278	0.222	3.6
Minstral 3 8B (2512)	0.000105	0.00167	0.0134	0.107	1.7
Qwen3.6-35B-A3B	0.000814	0.0130	0.104	0.833	13.3
Tencent Hy3 (295B)	0.000298	0.00477	0.0382	0.306	4.9
Ling-1T	0.000203	0.00326	0.0260	0.208	3.3
MiMo-V2.5-Pro	0.000217	0.00347	0.0278	0.222	3.6

1K = 1024, 1M = 1024²。RI 至少为 1 时保留一位小数, 小于 1 时保留三位有效数字; 精确值见机器数据。

例如, Qwen3.5-2B 在 $U = 1K$ 时, 输入量为 8 388 608 Byte, 一次写入量为 37 748 736 Byte, 故

$$RI = \frac{1024(2048 + 6144)}{3 \times 2048 \times 6144} \approx 0.222.$$

4 结果说明

固定 D, F 后, Q_R 与末态有效权重容量固定, Q_S 和 RI 随 U 线性增长。这与 QKV 都是一次装载后的复用关系。专家的选择与替换策略可能使其实际 U 较小; 替换更频繁时, 同一装载服务的向量数更少。本表扫描 U , 不从模型尺寸推断实际替换频率。

固定 U 时, $RI = (U/3)(1/D + 1/F)$ 。本表中 Qwen3.6 的单专家宽度 $F = 512$, 对应最高 RI; Minstral 的 D, F 组合对应最低 RI。比较依据是所选三矩阵的维度, 模型名中的总参数标签不进入公式。

Qwen3.5 与 MiMo 的 D, F 互换, $D + F$ 与 DF 均相同, 所以各档 U 下的 Q_S 、 Q_R 、RI 和末态有效容量相同。它们的 gate/up 与 down 分项输入、以及共享扣除量不同; 汇总相同符合当前计数边界。固定模型来源、精确字节及复算记录见本目录 README 与 data/; 数学入口为 Table II(a)。