

六模型 Attention 的驻留与输入需求

逐前缀 Prefill 与单步 Decode: 36 个精确工况

WS128-INT8-semantic-banks-v1

1 对象、窗口与六模型概览

本文采用已审阅 Step 3 版本 (e472a0d) 的共同方法, 取六模型各一个既定完整/global GQA 子层。每模型包含 Prefill、Decode 各 $L = 1024, 16384, 131072$, 共 36 个工况; $1K = 1024$ 。这些层型选择不代表全模型。Qwen 的线性 Attention、MiMo 的 SWA、视觉/音频、MTP、embedding、LM head 均不展开。

模型	层号	H_q	H_{kv}	d_{QK}	d_V	$g = H_q/H_{kv}$
Qwen3.5-2B	3	8	2	256	256	4
Ministral 3 8B (2512)	0	32	8	128	128	4
Qwen3.6-35B-A3B	3	16	2	256	256	8
Tencent Hy3 (295B)	1	64	8	128	128	8
Ling-1T	4	64	8	128	128	8
MiMo-V2.5-Pro	7	128	8	192	128	16

层号从 0 起。 H_q, H_{kv}, d_{QK}, d_V 独立保留, 不用 hidden size 反推头宽。Qwen 原生 output gate 是 Attention 输出后的门控, 不增加 query head 或 KV 状态。MiMo global 层没有 sink token, Value 在写入缓存前乘 0.612; 这些处理保留于数字交接。

研究窗口 Prefill 从本段空状态开始, 依次写入 token i 的 K/V, 再对可见前缀 $1:i$ 完成所有 query heads 的 QK 和 AV, 直到 L 。Decode 初态已有 $L - 1$ 个 token, 只追加一个, 再以可见长度 L 求值。两个窗口最终容量相同, 累计写入不同; 不能将最终容量直接当作 Decode 的 Q_R 。

精度与边界 共同参考是 128×128 的独立语义 tile bank, 各角色为 INT8、每元素 1 Byte。ports 累计每个 tile 接收的有效输入, 作为主口径; operator 累计整矩阵阶段入口, 作为对照。 $RI = Q_S/Q_R$ 分别在各自边界求比, 不平均分项 RI。原生 BF16/FP8 声明保留在来源中; 本稿不构成六模型 INT8 精度验证。

上下文条件 除 Ling 外, 固定 checkpoint 的最大位置长度覆盖三档 L 。Ling 原始 config 为 32768, 128K 仅在官方 YaRN 条件下纳入: factor=4、original_max_position_embeddings=32768、type=yarn, 并设置运行端 `--max-model-len 131072`。原始 config 不改; 不重新裁定 RoPE 实现差异, 也不声称已验证长上下文质量。

2 两种 resident 方向与精确计数

对于每个 KV head，列向量写法为

$$\mathcal{K}_i \in \mathbb{R}^{i \times d_{QK}}, \quad \mathcal{V}_i \in \mathbb{R}^{d_V \times i}, \quad s_i = \mathcal{K}_i q_i, \quad o_i = \mathcal{V}_i p_i.$$

K 沿序列行增长，V 沿序列列增长。每 KV head 只保留一份状态，由组内 g 个 query heads 共享；每个 query head 的 query 和系数向量仍分别计数。`repeat_kv` 的求值广播不等于额外持久副本。

一次追加 每 KV head 写入 K 的 $1 \times d_{QK}$ 行和 V 的 $d_V \times 1$ 列。K 行按输入块切为 $1 \times k_b$ ；V 列按输出块切为 $n_a \times 1$ 。固定绝对 token 坐标，旧 token 不移动、不重写，跨 tile 时只写新有效元素。

$$\Delta Q_{RK} = H_{kv} d_{QK}, \quad \Delta Q_{RV} = H_{kv} d_V.$$

设 $c(x) = \lceil x/128 \rceil$ 。一个可见前缀 i 的分项为：

任务	$Q_S^{\text{operator}}(i)$	$Q_S^{\text{ports}}(i)$	tile 调用 $C(i)$
QK	$H_q d_{QK}$	$H_q d_{QK} c(i)$	$H_q c(i) c(d_{QK})$
AV	$H_q i$	$H_q i c(d_V)$	$H_q c(d_V) c(i)$

所有字节宽度在本次代入为 1；符号角色 b_q, b_p, b_K, b_V 对应 query、系数、K、V，通式见共享方法。QK 输出 scores 不另加一次输入；softmax 后系数在 AV 入口计入。QK 与 AV 是不同输入身份，operator 汇总无共享输入扣除，数据中显式保存扣除量 0。

令 $L = 128m + r$ ， $0 \leq r < 128$ ，定义

$$P(L) = \frac{L(L+1)}{2}, \quad S(L) = 64m(m+1) + (m+1)r.$$

Prefill 的累计需求为

$$\begin{aligned} Q_{S_{\text{pre}}}^{\text{ports}} &= H_q [d_{QK} S(L) + c(d_V) P(L)], \\ Q_{S_{\text{pre}}}^{\text{operator}} &= H_q [L d_{QK} + P(L)], \\ Q_{R_{\text{pre}}} &= L H_{kv} (d_{QK} + d_V), \\ C_{\text{pre}} &= H_q [c(d_{QK}) + c(d_V)] S(L). \end{aligned}$$

Decode 取上表 $i = L$ 的两项和，写入仅为 $H_{kv} (d_{QK} + d_V)$ 。分项字节、分项 RI 与调用均保存于 JSON，不因汇总而消失。这里没有分配 $L \times L$ Attention 矩阵，没有以 $L^2/2$ 近似三角和。

3 代表代入：共享组与不等宽头

Qwen3.6, $L = 1024$ 取 $(H_q, H_{kv}, d_{QK}, d_V) = (16, 2, 256, 256)$, $P(1024) = 524800$, $S(1024) = 4608$, $c(256) = 2$ 。Prefill 的 QK/AV ports 输入分别为

$$16 \cdot 256 \cdot 4608 = 18874368, \quad 16 \cdot 2 \cdot 524800 = 16793600 \text{ Byte.}$$

两项写入均为 $1024 \cdot 2 \cdot 256 = 524288$ Byte；调用均为 147456。因此 ports 汇总 $(Q_S, Q_R, C) = (35667968, 1048576, 294912)$, $RI = 2177/64$ 。operator 输入则为 $4194304 + 8396800 = 12591104$ Byte, $RI = 1537/128$ 。

Decode 的 QK/AV ports 输入分别为 32768/32768 Byte, 写入 512/512 Byte, 调用 256/256；汇总为 $(65536, 1024, 512)$, $RI = 64$ 。operator 是 $4096 + 16384 = 20480$ Byte, $RI = 20$ 。初态有效 KV 为 $1023 \cdot 1024 = 1047552$ Byte, 最终为 1048576 Byte；新增 $Q_R = 1024$ Byte。

Ministral 与 Qwen3.6 同一 L 下两者的 ports 输入和调用逐项相同： $H_q d_{QK} = 4096$, $H_q c(d_V) = 32$, QK/AV 的调用因子均为 32。Ministral 每 token KV 写入为 2048 Byte, Qwen3.6 为 1024 Byte, 所以后者 ports RI 恰好加倍。两模型 operator 输入不同, 因为该边界不把 AV 输入按输出块重放。

MiMo 的 $192 = 128 + 64$ $L = 1024$ Decode 的 QK 输入为 $128 \cdot 192 \cdot 8 = 196608$ Byte, AV 为 $128 \cdot 1024 = 131072$ Byte。QK 的 2048 次调用中, 1024 次接收 128 Byte, 1024 次接收 64 Byte；AV 另有 1024 次 128 Byte 调用。完整汇总为 $(327680, 2560, 3072)$, ports $RI=128$, operator $RI=304/5$ 。

对应 Prefill: QK ports 为 113246208 Byte, AV 为 67174400 Byte；写入分别 1572864/1048576 Byte, 调用分别 1179648/589824。汇总 $(180420608, 2621440, 1769472)$, ports $RI=2753/40$ ；operator 输入 92340224 Byte, $RI=1409/40$ 。

尾片的含义 K 每次追加分为 1×128 与 1×64 , V 为 128×1 。有效 payload 只计实际 192 维, 完整 tile 与调用仍按两个输入块计；不把半宽尾片换成半次调用, 不推断服务时间减半。

4 36 工况的 ports 主结果

模型	L	Prefill RI	Decode RI
Qwen3.5-2B	1024	$\frac{2177}{128}$	32
	16384	$\frac{32897}{128}$	512
	131072	$\frac{262273}{128}$	4096
Ministral 3 8B (2512)	1024	$\frac{2177}{128}$	32
	16384	$\frac{32897}{128}$	512
	131072	$\frac{262273}{128}$	4096
Qwen3.6-35B-A3B	1024	$\frac{2177}{64}$	64
	16384	$\frac{32897}{64}$	1024
	131072	$\frac{262273}{64}$	8192
Tencent Hy3 (295B)	1024	$\frac{2177}{64}$	64
	16384	$\frac{32897}{64}$	1024
	131072	$\frac{262273}{64}$	8192
Ling-1T	1024	$\frac{2177}{64}$	64
	16384	$\frac{32897}{64}$	1024
	131072	$\frac{262273}{64}$	8192
MiMo-V2.5-Pro	1024	$\frac{2753}{40}$	128
	16384	$\frac{41153}{40}$	2048
	131072	$\frac{327873}{40}$	16384

上表只呈现 RI。对应精确 Byte、调用、QK/AV 分项和布局均在 `data/results.json` 与 `data/results.csv`。Qwen3.5/Ministral 相同 RI 并不意味着相同总需求；相同 L 时后者 ports 输入、写入、容量与调用均是前者两倍。Qwen3.6/Hy3/Ling 的 ports RI 也相同，但 Hy3/Ling 的 ports 输入、写入、容量、调用是 Qwen3.6 两倍。Hy3 与 Ling 的四个 Attention 头参数完全相同，所以在此单层参考内两边界结果相同。

5 operator 对照：相同主比值下的入口差异

模型	L	Prefill RI	Decode RI
Qwen3.5-2B	1024	$\frac{1537}{256}$	10
	16384	$\frac{16897}{256}$	130
	131072	$\frac{131585}{256}$	1026
Ministral 3 8B (2512)	1024	$\frac{1281}{128}$	18
	16384	$\frac{16641}{128}$	258
	131072	$\frac{131329}{128}$	2050
Qwen3.6-35B-A3B	1024	$\frac{1537}{128}$	20
	16384	$\frac{16897}{128}$	260
	131072	$\frac{131585}{128}$	2052
Tencent Hy3 (295B)	1024	$\frac{1281}{64}$	36
	16384	$\frac{16641}{64}$	516
	131072	$\frac{131329}{64}$	4100
Ling-1T	1024	$\frac{1281}{64}$	36
	16384	$\frac{16641}{64}$	516
	131072	$\frac{131329}{64}$	4100
MiMo-V2.5-Pro	1024	$\frac{1409}{40}$	$\frac{304}{5}$
	16384	$\frac{16769}{40}$	$\frac{4144}{5}$
	131072	$\frac{131457}{40}$	$\frac{32816}{5}$

operator 保留各阶段真实入口。Qwen 的 $d_V = 256$ 使 AV 的同一系数在 ports 被两个输出块接收，operator 只记一次；Ministral、Hy3、Ling 和 MiMo 的 $d_V = 128$ 无此倍数。因此 ports 相同 RI 的模型组在 operator 下仍可能不同，不能用 operator 的 Q_S 除以其它边界选择下的分母或平均分项 RI。

6 容量、追加与窗口关系

最终有效容量与完整 tile 槽位 设 $R_1 = H_{kv}(d_{QK} + d_V)$ Byte。Prefill 初始有效容量为 0，Decode 为 $(L - 1)R_1$ ；两者最终有效容量均为 LR_1 。最终 resident tile 数为

$$H_{kv}[c(L)c(d_{QK}) + c(d_V)c(L)],$$

完整分配容量为该数乘 16384 Byte。JSON 同时保存初始/最终有效容量、初始/最终活跃 tile 的完整槽位，以及按有效形状的 tile 直方图。初始槽位字段描述当时活跃 tile 覆盖，不额外假定运行端何时物理预分配全部最终槽位。

模型	R_1 (Byte)	1K 有效 MiB	1K 分配 MiB	1K tile 数
Qwen3.5-2B	1024	1	1	64
Minstral 3.8B	2048	2	2	128
Qwen3.6-35B-A3B	1024	1	1	64
Tencent Hy3	2048	2	2	128
Ling-1T	2048	2	2	128
MiMo-V2.5-Pro	2560	2.5	3	192

1MiB = 1048576 Byte。16K 和 128K 的最终有效容量、完整分配容量和 tile 数分别是 1K 的 16 倍和 128 倍。MiMo 128K 的有效容量为 320 MiB、完整槽位 384 MiB；差值来自每个 K 输入方向的 64 维尾片，不是额外有效 KV。

有效尾块不只出现在 MiMo 三档最终 L 都整除 128，但 Prefill 中间前缀经过所有序列尾宽 1-127；Decode 初态的 $L - 1$ 亦有 127 token 尾块。分项 `valid_N_K_call_histogram` 保存实际求值的有效形状，`layout` 保存最终驻留形状，`append` 保存新片写入形状与次数，三者分别记录。切片次数是逻辑写入事件数，不是介质写事务数。

窗口衔接 对每项及汇总，两个边界分别满足

$$Q_{Spre}(L) - Q_{Spre}(L - 1) = Q_{Sdec}(L), \quad Q_{Rpre}(L) - Q_{Rpre}(L - 1) = Q_{Rdec}(L),$$

调用数也满足同样差量；RI 本身不做差量相减。在前五个等宽模型、 L 整除 128 时，ports 有

$$\frac{Q_{Spre}}{Q_{Sdec}} = \frac{2L + 129}{4}, \quad \frac{Q_{Rpre}}{Q_{Rdec}} = L, \quad \frac{RI_{pre}}{RI_{dec}} = \frac{2L + 129}{4L}.$$

MiMo 的相应输入比是 $(5L + 386)/10$ ，RI 比为 $(5L + 386)/(10L)$ ，体现不等宽 QK/V 的影响。

7 独立复算、回归与使用限制

主计算 `scripts/generate.py` 从固定 `data/models.json` 提取六模型原生参数，调用共享闭式 API；36 条结果重新生成，未复制 `pilot` 数据。角色精度、tile 形状、模型序与三档 L 在入口断言。整数不先转浮点；非整数分数保存为 `numerator/denominator` 对。

独立预期值 `scripts/check.py` 不导入主生成脚本或共享计数函数。它重新读取六份原始 `config` 和 `checkpoint metadata`，并核对固定实现中的头宽、共享组、`cache update`、`global/SWA` 分支及 `Value` 缩放定位。数值预期按绝对序列 `tile` 反向累加：一个 `tile` 从首次出现到填满，依次贡献每个部分宽度；填满后在其余前缀继续使用。再与真实 QK 输入块、AV 输出块笛卡尔组合，汇总有效输入宽度与调用。追加单独遍历新 `token` 和维度切片，容量由真实 `tile` 有效面积相加；均不调用生产闭式。

检查	数量	范围
完整主工况	36	两边界汇总/分项、精确 RI、调用、初末容量、追加切片、有效调用形状
显式边界身份枚举	24	六模型各 $L = 1, 127, 128, 129$ ；按 <code>query/KV head</code> 、 <code>tile</code> 和输入/写入元素身份验证独立 <code>oracle</code>
主长度前缀差量	18	六模型三档 L ；逐分项与汇总检查 <code>Prefill</code> 差量等于 <code>Decode</code>
<code>pilot</code> 重叠回归	14	<code>Ministral/Qwen3.6</code> 各六条及 <code>MiMo 1K</code> 两条；旧结果已有全部语义字段逐项一致
原始结构审计	6	原始 <code>config</code> 、 <code>revision</code> 、实现锚点和来源 <code>SHA-256</code>

128K 检查只保存紧凑宽度/形状直方图与 `resident tile` 网格，不产生 $L \times L$ 数据或按调用展开的大事件列表。逐项预期和审计证据保存在 `data/checks.json`，来源文件哈希在 `data/config.json`。

使用边界 本研究假定足够逻辑 `resident` 服务单元，独立语义 `bank` 和当前逐前缀组织。它建立矩阵阶段逻辑需求，不含容量驱逐造成的重载，不把复制或数字交接零成本化。页/块擦写、编码、`verify`、`refresh`、数字累加、`softmax`、`RoPE` 和实际调度需要另外的实现模型。本文不据总 RI 推断单 `macro` 时间、`token/s`、端到端性能或器件排名。

复现 从仓库根设置 `TASK2_PYTHON=/opt/anaconda3/bin/python` 后运行 `table_IIb/03_attention/scripts/build.sh` (前缀为任务目录)。该命令复核现存数据再编译本稿；生成/检查加 `--emit` 才刷新数据。`scripts/render.py` 只渲染，逐页视觉确认另记于 `data/pdf_qa.json`。

8 固定来源与证据定位

以下路径均相对 `tasks/task2_table_II_workloads/`；完整 URL、版本与原件 SHA-256 在既有 `data/sources.json`，本次实际使用的文件哈希另在 `03_attention/data/config.json`（位于 `table_IIB/` 下）。

Qwen3.5-2B 官方 Qwen/Qwen3.5-2B, revision

15852e8c16360a2fea060d615a32b45270f8a8fc。

`literature/01_qwen35_2b/raw/config.json`: `text_config` 的 `heads`、`head_dim`、`layer_types`；`literature/00_shared/raw/transformers/modeling_qwen3_5.py`: 749–821 行，Q/G 切分、K/V cache 更新和输出 `gate`。

Ministral 3 8B Base 2512 官方 mistralai/Ministral-3-8B-Base-2512, revision

d4883f9b36aa2e5d775730d3fdb3d30de51a8ef。

`literature/02_ministral3_8b/raw/config.json` 的 `text_config` 与同目录 `params.json` 交叉核对；后者 `v_head_dim=null`，以固定 `modeling_ministral3.py` 的 V 投影构造确认回落至 128。

Qwen3.6-35B-A3B 官方 Qwen/Qwen3.6-35B-A3B, revision

995ad96eacd98c81ed38be0c5b274b04031597b0。

`literature/03_qwen36_35b_a3b/raw/config.json`: `text_config`；共享 `modeling_qwen3_5_moe.py` 第 751 行起的 Attention。使用确切 checkpoint，不以 Qwen3.5 权重替代。

Tencent Hy3 官方 tencent/Hy3, revision

a960ebc3da325ba167f069f76c41eb62c9280d22。

`literature/04_hy3_295b/raw/config.json`: `num_attention_heads`、`num_key_value_heads`、`head_dim`；共享 `modeling_hy_v3.py` 第 210–280 行。

Ling-1T 官方 inclusionAI/Ling-1T, revision

268f2aa76aa8cf5b36ca33805481cea91133327e。

`literature/05_ling_1t/raw/config.json`；同目录 `modeling_bailing_moe_v2.py` 第 441–546 行的融合 QKV、cache update 和 `repeat_kv`；`README.md` 第 238–250 行的官方 YaRN 扩展条件。RoPE 局部实现疑义不改变完整 128 维缓存计数。

MiMo-V2.5-Pro 官方 XiaomiMiMo/MiMo-V2.5-Pro, revision

21d1ecfec7bd70f31be25ca49d7edd21f003659。

`literature/06_mimo_v25_pro/raw/config.json`: `hybrid_layer_pattern`、`head_dim`、`v_head_dim`；同目录 `modeling_mimo_v2.py` 第 215–309 行，global 分支、Value 缩放与缓存更新。

共同计量 `shared/data/conventions.json`、`shared/tex/counting_method.zh.tex` 与 `shared/scripts/counting.py`。Transformer 上游实现固定 commit 与许可证沿用原始来源包。六份 `STRUCTURE.zh.md` 是已审阅提取卡，原件未改。