

注意力的输入复用与 RI

2026 年 10 月 2 日

1 对象与公式

取单序列、一个完整因果 GQA 层的 QK 与 AV 两个矩阵阶段。 H_q 为 query 头数, H_{kv} 为 KV 头数, $g = H_q/H_{kv}$; d_{QK} 与 d_V 为原生头维, L 为本次追加后可见长度。每个 KV head 保存一份 K/V, 由组内 g 个 query heads 共享。

沿用 Table II(a) 的 $RI = Q_S/Q_R$ 与每元素 1 Byte 口径。在有效前缀 i , K 的形状为 $i \times d_{QK}$, V 为 $d_V \times i$; 每个 query head 在 QK 阶段输入 d_{QK} 个 query 元素, 在 AV 阶段输入 softmax 后的 i 个系数。历史 K/V 是 resident 操作数, 不重复列为 streaming 输入。两阶段输入分别计入, 输出不另加; Q_R 只计窗口内新写入的唯一逻辑 K/V。

预填充 (Prefill) 从空 KV 建到 L , 计完 L 个位置的因果有效范围:

$$Q_S = \sum_{i=1}^L H_q(d_{QK} + i) = H_q \left[Ld_{QK} + \frac{L(L+1)}{2} \right], \quad Q_R = LH_{kv}(d_{QK} + d_V),$$

$$RI = \frac{g[d_{QK} + (L+1)/2]}{d_{QK} + d_V}.$$

这是三角求和: 第 i 个 query 使用当时可见的 i 个 K/V, AV 输入随前缀增长。每个 token 的 K/V 只写一次, 故写入是 L 份新状态之和, 不是每次重写整个前缀。

单步解码 (Decode) 已有 $L-1$ 个 token 的 KV, 写入一份新的 K/V 后, 对长度 L 的完整前缀求值:

$$Q_S = H_q(d_{QK} + L), \quad Q_R = H_{kv}(d_{QK} + d_V),$$

$$RI = \frac{g(d_{QK} + L)}{d_{QK} + d_V}.$$

最终有效 KV 容量均为 $LH_{kv}(d_{QK} + d_V)$ Byte; 初始容量在 Prefill 为 0, 在 Decode 为 $(L-1)H_{kv}(d_{QK} + d_V)$ Byte。容量与本窗口的累计写入量分别记录。

2 模型信息

六模型均取固定版本中的完整/global GQA 层, 层号从 0 起。

模型	所选层	H_q	H_{kv}	g	d_{QK}	d_V
Qwen3.5-2B	3	8	2	4	256	256
Ministral 3 8B (2512)	0	32	8	4	128	128
Qwen3.6-35B-A3B	3	16	2	8	256	256
Tencent Hy3 (295B)	1	64	8	8	128	128
Ling-1T	4	64	8	8	128	128
MiMo-V2.5-Pro	7	128	8	16	192	128

各模型保留原有上下文设置; Ling-1T 的 64K 沿用既定官方扩展配置。¹ MiMo 的 Value 在写入前乘 0.612, 维度不变; 所选全局层无 sink。

¹YaRN: factor=4、original_max_position_embeddings=32768、type=yarn, 并设 `--max-model-len 131072`; 原始配置不改。

3 代入结果

两表以模型为行、可见长度 $L \in \{1K, 8K, 64K\}$ 为列，单元格为小数 RI。

预填充 (Prefill) 的 RI: 空 KV 建到 L

模型	$L = 1K$	$L = 8K$	$L = 64K$
Qwen3.5-2B	6.0	34.0	258.0
Ministral 3 8B (2512)	10.0	66.0	514.0
Qwen3.6-35B-A3B	12.0	68.0	516.0
Tencent Hy3 (295B)	20.0	132.0	1028.0
Ling-1T	20.0	132.0	1028.0
MiMo-V2.5-Pro	35.2	214.4	1648.0

单步解码 (Decode) 的 RI: 已有 $L - 1$, 追加一个

模型	$L = 1K$	$L = 8K$	$L = 64K$
Qwen3.5-2B	10.0	66.0	514.0
Ministral 3 8B (2512)	18.0	130.0	1026.0
Qwen3.6-35B-A3B	20.0	132.0	1028.0
Tencent Hy3 (295B)	36.0	260.0	2052.0
Ling-1T	36.0	260.0	2052.0
MiMo-V2.5-Pro	60.8	419.2	3286.4

$1K = 1024$, $1M = 1024^2$ 。RI 至少为 1 时保留一位小数，小于 1 时保留三位有效数字；精确值见机器数据。

例如，Qwen3.5-2B 在 Prefill、 $L = 1K$ 时， $Q_S = 8[1024 \times 256 + 1024 \times 1025/2] = 6\,295\,552$ Byte， $Q_R = 1024 \times 2 \times (256 + 256) = 1\,048\,576$ Byte，故 $RI \approx 6.0$ 。

4 结果说明

固定头维时，RI 随 g 成比例增长。两个 Qwen 模型的头维相同，Qwen3.6 的 g 加倍，RI 也加倍。

Prefill 累计全部 L 个位置，Decode 只计算当前位置；后者的写入仅为前者的 $1/L$ 。同一 L 下， $RI_{\text{Decode}}/RI_{\text{Prefill}} = (d_{QK} + L)/[d_{QK} + (L + 1)/2]$ ，长前缀时趋近 2。该关系来自当前窗口和因果前缀计数。

Hy3 与 Ling 的头结构相同，RI 相同；MiMo 直接使用原生 192/128 头维。

固定模型来源、精确字节及复算记录见本目录 README 与 data/；数学入口为 Table II(a)。